

VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY
FACULTY OF COMPUTER SCIENCE AND ENGINEERING



HK251

Báo cáo Bài tập lớn (học phần Học Sâu)

**Phân loại âm thanh đô thị
trên bộ dữ liệu
UrbanSound8K sử dụng
Log-Mel Spectrogram và
CNN, ResNet**

Advisor(s): Thầy Huỳnh Văn Thống

Student(s): Ngô Thái Minh Tiến 2252809

HO CHI MINH CITY, APRIL 2026

Contents

1	Mở đầu	1
1.1	Bối cảnh nghiên cứu	1
1.2	Động lực thực hiện đề tài	1
1.3	Mục tiêu nghiên cứu	2
1.4	Cấu trúc báo cáo	2
2	Xác định bài toán và bộ dữ liệu	3
2.1	Phát biểu bài toán	3
2.2	Ý nghĩa của bài toán urban sound classification	3
2.3	Lý do lựa chọn bộ dữ liệu UrbanSound8K	4
2.4	Mô tả tổng quan về bộ dữ liệu	4
2.5	Các lớp âm thanh trong dataset	5
2.5.1	Đặc điểm chung của các lớp	6
2.5.2	Khó khăn trong phân loại giữa các lớp	6
2.6	Kết quả phân tích dữ liệu khám phá	6
2.6.1	Kiểm tra tính đúng đắn giữa metadata và file audio	6
2.6.2	Phân tích sample rate	7
2.6.3	Phân tích số kênh âm thanh	7
2.6.4	Phân tích thời lượng audio	8
2.7	Quyết định tiền xử lý rút ra từ EDA	9
3	Tổng quan tài liệu	9
3.1	Tổng quan về phân loại âm thanh	9
3.2	Các hướng tiếp cận truyền thống	9
3.2.1	Đặc trưng thủ công	9
3.2.2	Bộ phân loại truyền thống	10
3.3	Sự chuyển dịch sang Deep Learning	10
3.4	Biểu diễn tín hiệu âm thanh trong học sâu	10
3.4.1	Waveform	10
3.4.2	Spectrogram	11
3.4.3	Mel spectrogram và log-Mel spectrogram	11
3.5	CNN trong bài toán audio classification	11
3.6	Residual Network và ResNet18	12
3.6.1	Ý tưởng residual learning	12
3.6.2	Áp dụng ResNet cho spectrogram	12



3.7	Data augmentation trong audio classification	12
3.7.1	Vai trò của augmentation	12
3.7.2	Augmentation trong miền spectrogram	12
3.8	Khoảng trống mà đề tài tập trung	13
4	Triển khai thuật toán Deep Learning	13
4.1	Tổng quan pipeline	13
4.2	Tiền xử lý dữ liệu âm thanh	14
4.2.1	Chuyển về mono	14
4.2.2	Resample về 22050 Hz	14
4.2.3	Pad hoặc truncate về 4.0 giây	15
4.2.4	Trích xuất log-Mel spectrogram	15
4.2.5	Chuẩn hóa đặc trưng	15
4.3	Tổ chức dữ liệu train, validation và test	15
4.4	Xây dựng Dataset và DataLoader	16
4.4.1	Thiết kế Dataset	16
4.4.2	Thiết kế DataLoader	16
4.5	Mô hình CNN	16
4.5.1	Vai trò của CNN	16
4.5.2	Lý do chọn CNN	17
4.6	Mô hình ResNet18	17
4.6.1	Lý do lựa chọn ResNet18	17
4.6.2	Điều chỉnh đầu vào cho spectrogram	17
4.6.3	Điều chỉnh stem của mô hình	17
4.7	Data augmentation trong miền spectrogram	17
4.7.1	Mục tiêu của augmentation	17
4.7.2	Các phép augmentation được áp dụng	18
4.7.3	Lý do chọn augmentation trong miền spectrogram	18
4.8	Chỉ số đánh giá và theo dõi thí nghiệm	18
4.8.1	Accuracy	18
4.8.2	Macro-F1	18
4.8.3	Confusion Matrix	19
4.8.4	Weights & Biases	19
5	Thiết kế thực nghiệm	19
5.1	Mục tiêu của phần thực nghiệm	19

5.2	Môi trường và phạm vi thực hiện	19
5.3	Chuẩn đầu vào cố định cho các thí nghiệm	20
5.4	Tổ chức các cấu hình thực nghiệm	20
5.4.1	Cấu hình 1: CNN baseline	20
5.4.2	Cấu hình 2: ResNet18 improved không pretrained	20
5.4.3	Cấu hình 3: ResNet18 + augmentation không pretrained	21
5.5	Quy trình huấn luyện và đánh giá	21
5.5.1	Tách train, validation và test	21
5.5.2	Quy trình huấn luyện	21
5.5.3	Quy trình đánh giá	21
5.6	Tiêu chí so sánh	21
5.6.1	So sánh theo Accuracy	21
5.6.2	So sánh theo Macro-F1	22
5.6.3	So sánh theo confusion matrix và classification report	22
5.7	Ý nghĩa của việc sử dụng nhiều mô hình	22
5.8	Tính tái lập của thực nghiệm	22
6	Đánh giá, so sánh và phân tích thực nghiệm	22
6.1	Kết quả tổng quan	22
6.2	Phân tích kết quả của CNN	23
6.2.1	Hiệu năng tổng thể	23
6.2.2	Ý nghĩa của kết quả CNN	23
6.2.3	Phân tích theo từng lớp	23
6.3	Phân tích kết quả của ResNet18	25
6.3.1	Hiệu năng tổng thể	25
6.3.2	Giải thích khả năng chưa vượt được CNN	25
6.3.3	Phân tích theo từng lớp	25
6.4	Phân tích kết quả của ResNet18 + augmentation	26
6.4.1	Hiệu năng tổng thể	26
6.4.2	Ý nghĩa của việc Macro-F1 tăng	27
6.4.3	Phân tích theo từng lớp	27
6.5	So sánh trực tiếp giữa ba mô hình	28
6.5.1	So sánh theo Accuracy	28
6.5.2	So sánh theo Macro-F1	28
6.5.3	Góc nhìn cân bằng	28
6.6	Phân tích confusion matrix	29



6.7	Trả lời các câu hỏi nghiên cứu	31
6.7.1	CNN baseline và ResNet18 khác nhau như thế nào?	31
6.7.2	Việc điều chỉnh ResNet18 cho spectrogram có giúp hay không? . . .	31
6.7.3	Augmentation có tác động như thế nào?	31
6.8	Hạn chế của đề tài	31
7	Kết luận và hướng phát triển	32
7.1	Kết luận chung	32
7.2	Những kết quả nổi bật	32
7.3	Ý nghĩa học thuật và thực tiễn	33
7.4	Hướng phát triển tiếp theo	33



List of Figures

2.1	Tóm tắt kết quả EDA	5
2.2	Phân phối sample rate	7
2.3	Phân phối kênh	8
2.4	Phân phối thời lượng âm thanh	8
3.1	Minh họa waveform của âm thanh siren	11
3.2	Minh họa spectrogram của âm thanh siren	11
6.1	Kết quả log wandb của CNN	24
6.2	Kết quả resnet từ wandb	26
6.3	Kết quả Resnet với bộ dữ liệu tăng cường	28
6.4	Confusion Matrix của CNN	29
6.5	Confusion Matrix của ResNet18	30
6.6	Confusion Matrix của ResNet18 + augmentation	30



List of Tables

6.1	So sánh kết quả tổng quan giữa các mô hình	23
6.2	F1-score theo lớp của CNN baseline	24
6.3	F1-score theo lớp của ResNet18 improved	26
6.4	F1-score theo lớp của ResNet18 + augmentation	27

1 Mở đầu

1.1 Bối cảnh nghiên cứu

Trong những năm gần đây, các bài toán xử lý dữ liệu đa phương tiện bằng học sâu đã phát triển mạnh mẽ, không chỉ trong thị giác máy tính mà còn trong xử lý âm thanh. Nếu như dữ liệu ảnh có tính trực quan cao và tương đối dễ biểu diễn dưới dạng ma trận hai chiều, thì dữ liệu âm thanh lại tồn tại dưới dạng tín hiệu theo thời gian, có tính liên tục, độ dài không cố định và thường bị ảnh hưởng mạnh bởi nhiễu môi trường. Điều này khiến cho việc xây dựng các hệ thống nhận diện âm thanh tự động trở thành một thách thức quan trọng nhưng cũng rất có giá trị thực tiễn.

Trong môi trường đô thị, âm thanh xuất hiện với mật độ cao và rất đa dạng. Các loại âm thanh như tiếng máy điều hòa, còi xe, tiếng trẻ em chơi đùa, tiếng chó sủa, tiếng khoan, tiếng động cơ, tiếng súng, tiếng búa khoan, còi báo động hay nhạc đường phố đều có thể mang thông tin hữu ích cho nhiều ứng dụng khác nhau. Một hệ thống có khả năng tự động phân loại các âm thanh này có thể được sử dụng trong giám sát môi trường, thành phố thông minh, hỗ trợ an ninh, giám sát sự kiện bất thường, hoặc làm tiền đề cho các hệ thống phân tích ngữ cảnh đô thị.

Từ nhu cầu đó, bài toán *urban sound classification* trở thành một hướng nghiên cứu có ý nghĩa cả về mặt học thuật lẫn ứng dụng. Bài toán này yêu cầu mô hình học máy phải nhận diện được lớp của một đoạn âm thanh ngắn dựa trên đặc trưng âm học của nó. Trong bối cảnh học sâu, một hướng tiếp cận phổ biến là biến đổi tín hiệu âm thanh sang miền thời gian – tần số bằng các biểu diễn như spectrogram hoặc Mel spectrogram, sau đó sử dụng các kiến trúc mạng nơ-ron tích chập để trích xuất đặc trưng và thực hiện phân loại.

1.2 Động lực thực hiện đề tài

Đề tài này được lựa chọn dựa trên ba động lực chính.

Thứ nhất, đây là một bài toán điển hình của lĩnh vực Deep Learning ứng dụng trên dữ liệu ngoài ảnh, phù hợp với mục tiêu học tập của môn học. So với các bài toán image classification quen thuộc, audio classification mang lại cơ hội tiếp cận một loại dữ liệu khác, đồng thời giúp người thực hiện hiểu sâu hơn về vai trò của tiền xử lý, biểu diễn đặc trưng và thiết kế pipeline.

Thứ hai, bộ dữ liệu UrbanSound8K là một tập dữ liệu có kích thước vừa phải, cấu trúc rõ ràng, đủ lớn để thực hiện thực nghiệm học sâu nhưng vẫn phù hợp với phạm vi

một bài tập lớn cá nhân. Dataset này cũng có tính học thuật cao vì đã được sử dụng rộng rãi trong các nghiên cứu về nhận diện âm thanh môi trường.

Thứ ba, đề tài cho phép triển khai một pipeline hoàn chỉnh từ phân tích dữ liệu, tiền xử lý, xây dựng Dataset/DataLoader, huấn luyện mô hình, đánh giá kết quả, trực quan hóa thí nghiệm đến viết báo cáo học thuật. Đây là một cơ hội tốt để tổng hợp kiến thức lý thuyết và kỹ năng thực hành trong cùng một project.

1.3 Mục tiêu nghiên cứu

Mục tiêu tổng quát của đề tài là xây dựng và đánh giá một hệ thống phân loại âm thanh đô thị trên bộ dữ liệu UrbanSound8K bằng các mô hình học sâu dựa trên biểu diễn log-Mel spectrogram.

Từ mục tiêu tổng quát đó, đề tài cụ thể hóa thành các mục tiêu nhỏ như sau:

- Tìm hiểu đặc điểm của bộ dữ liệu UrbanSound8K, bao gồm cấu trúc dữ liệu, các lớp nhãn và các yếu tố không đồng nhất trong dữ liệu gốc.
- Thiết kế một pipeline tiền xử lý thống nhất để đưa toàn bộ dữ liệu về cùng chuẩn đầu vào.
- Trích xuất đặc trưng log-Mel spectrogram từ tín hiệu âm thanh.
- Xây dựng mô hình CNN baseline làm mốc so sánh.
- Triển khai mô hình ResNet18 đã được điều chỉnh để phù hợp với đầu vào spectrogram một kênh.
- Khảo sát tác động của augmentation trong miền spectrogram đối với hiệu năng mô hình.
- Đánh giá, so sánh và phân tích kết quả bằng các chỉ số Accuracy, Macro-F1 và Confusion Matrix.

1.4 Cấu trúc báo cáo

Phần còn lại của báo cáo được tổ chức như sau. Session 2 trình bày bài toán và bộ dữ liệu sử dụng. Session 3 tổng hợp cơ sở lý thuyết và các hướng nghiên cứu liên quan. Session 4 mô tả chi tiết phương pháp đề xuất, bao gồm pipeline tiền xử lý, biểu diễn đặc trưng và các mô hình được triển khai. Session 5 trình bày thiết kế thực nghiệm. Session 6

đưa ra kết quả, so sánh và thảo luận. Session 7 là kết luận và hướng phát triển tiếp theo. Cuối cùng, Session 8 tổng hợp thông tin nộp bài và các phụ lục cần thiết.

2 Xác định bài toán và bộ dữ liệu

2.1 Phát biểu bài toán

Bài toán được xét trong đề tài là bài toán phân loại âm thanh đa lớp có giám sát. Với mỗi đoạn âm thanh đầu vào có thời lượng ngắn, mô hình cần dự đoán nhãn tương ứng thuộc một trong mười lớp âm thanh đô thị đã được xác định trước.

Gọi x là một đoạn âm thanh đầu vào và y là nhãn lớp tương ứng. Khi đó, mô hình học sâu cần học một hàm ánh xạ:

$$f(x) \rightarrow y, \quad y \in \{1, 2, \dots, 10\}$$

trong đó đầu ra là xác suất hoặc nhãn lớp dự đoán cho mẫu đầu vào.

Bài toán này thuộc nhóm *supervised multi-class classification*, trong đó dữ liệu huấn luyện bao gồm các cặp (x_i, y_i) và mô hình được tối ưu để giảm sai số dự đoán trên tập huấn luyện, đồng thời đạt khả năng tổng quát hóa tốt trên tập kiểm thử.

2.2 Ý nghĩa của bài toán urban sound classification

Phân loại âm thanh đô thị là một bài toán có ý nghĩa thực tế cao. Trong bối cảnh đô thị hiện đại, các hệ thống tự động có thể sử dụng âm thanh như một nguồn tín hiệu quan trọng để hiểu môi trường xung quanh. Ví dụ, một hệ thống giám sát có thể phát hiện âm thanh bất thường như tiếng súng hoặc còi báo động để phát ra cảnh báo; một hệ thống phân tích giao thông có thể tận dụng âm thanh còi xe hoặc động cơ; một hệ thống quan trắc môi trường sống có thể phân tích mức độ tiếng ồn và thành phần âm thanh đặc trưng của khu vực.

Về mặt học thuật, đây cũng là một bài toán tiêu biểu để kiểm chứng khả năng của các mô hình Deep Learning trên dữ liệu âm thanh. Nó đòi hỏi sự kết hợp giữa xử lý tín hiệu số, biểu diễn đặc trưng và học sâu, từ đó giúp người học hình thành tư duy triển khai pipeline một cách hệ thống.

2.3 Lý do lựa chọn bộ dữ liệu UrbanSound8K

UrbanSound8K được lựa chọn vì đây là một trong những bộ dữ liệu chuẩn cho bài toán phân loại âm thanh môi trường, đặc biệt là âm thanh đô thị. Bộ dữ liệu này có ba ưu điểm nổi bật.

Thứ nhất, dữ liệu đã được gán nhãn rõ ràng theo từng lớp âm thanh, giúp phù hợp với bài toán phân loại có giám sát.

Thứ hai, bộ dữ liệu được chia sẵn thành 10 fold, tạo điều kiện thuận lợi cho việc tổ chức thí nghiệm theo train, validation và test mà vẫn đảm bảo tính tách biệt giữa các tập.

Thứ ba, kích thước dữ liệu ở mức vừa phải, đủ để huấn luyện các mô hình CNN và ResNet trong phạm vi tài nguyên tính toán cá nhân, đồng thời không quá nhỏ để khiến kết quả trở nên thiếu ý nghĩa.

2.4 Mô tả tổng quan về bộ dữ liệu

Theo kết quả EDA đã thực hiện, bộ dữ liệu UrbanSound8K trong đề tài có các đặc điểm chính sau:

- Tổng số mẫu: 8732 audio clips.
- Số lớp: 10.
- Số fold: 10.
- Duration trung bình của các audio clip khoảng 3.61 giây.
- Sample rate không đồng nhất, trải dài từ 8000 Hz đến 192000 Hz.
- Dữ liệu bao gồm cả mono và stereo.

```
{'num_samples': 8732,  
'num_classes': 10,  
'classes': ['air_conditioner',  
'car_horn',  
'children_playing',  
'dog_bark',  
'drilling',  
'engine_idling',  
'gun_shot',  
'jackhammer',  
'siren',  
'street_music'],  
'num_folds': 10,  
'folds': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10],  
'all_files_exist': True,  
'sample_rates': {'8000': 12,  
'11024': 7,  
'11025': 39,  
'16000': 45,  
'22050': 44,  
'24000': 82,  
'32000': 4,  
'44100': 5370,  
'48000': 2502,  
'96000': 610,  
'192000': 17},  
'channels': {'1': 739, '2': 7993},  
'duration_mean': 3.6075218292463376,  
'duration_min': 0.05,  
'duration_max': 4.036647314949202}
```

Figure 2.1: Tóm tắt kết quả EDA

Những đặc điểm này cho thấy dữ liệu gốc có mức độ không đồng nhất đáng kể, do đó cần có một chiến lược tiền xử lý nhất quán trước khi đưa vào huấn luyện mô hình.

2.5 Các lớp âm thanh trong dataset

Mười lớp âm thanh được sử dụng trong đề tài bao gồm:

- air_conditioner
- car_horn
- children_playing
- dog_bark

- drilling
- engine_idling
- gun_shot
- jackhammer
- siren
- street_music

2.5.1 Đặc điểm chung của các lớp

Các lớp trong UrbanSound8K có mức độ đặc trưng âm học khác nhau. Một số lớp như `car_horn`, `gun_shot` hoặc `siren` thường có các đặc trưng tương đối nổi bật và dễ phân biệt nhờ cấu trúc năng lượng tập trung hoặc thay đổi mạnh theo thời gian. Ngược lại, các lớp như `air_conditioner`, `engine_idling`, `drilling` hay `jackhammer` có thể khó hơn do mang tính cơ học, lặp lại và đôi khi có phổ năng lượng tương đối gần nhau.

2.5.2 Khó khăn trong phân loại giữa các lớp

Không phải mọi lớp đều có độ khó như nhau. Một số lớp mang tính liên tục và nhiều nền cao, khiến mô hình dễ nhầm lẫn. Ví dụ, `drilling` và `jackhammer` đều là các âm thanh cơ khí có năng lượng mạnh ở một số vùng tần số; `air_conditioner` và `engine_idling` đều mang tính nền, ổn định và ít biến đổi theo thời gian. Điều này khiến việc chỉ đánh giá bằng Accuracy là chưa đủ, mà cần bổ sung thêm Macro-F1 và confusion matrix.

2.6 Kết quả phân tích dữ liệu khám phá

2.6.1 Kiểm tra tính đúng đắn giữa metadata và file audio

Một bước quan trọng trong EDA là kiểm tra xem metadata có ánh xạ đúng sang các file audio hay không. Kết quả cho thấy việc mapping giữa thông tin trong metadata và file audio thực tế là chính xác hoàn toàn. Điều này đảm bảo rằng các bước xây dựng Dataset và DataLoader về sau sẽ dựa trên dữ liệu đúng, tránh lỗi sai nhãn hoặc sai đường dẫn.

2.6.2 Phân tích sample rate

Dữ liệu gốc có sample rate rất không đồng nhất, từ 8000 Hz đến 192000 Hz. Đây là một vấn đề quan trọng bởi sample rate ảnh hưởng trực tiếp đến miền tần số có thể biểu diễn và kích thước tín hiệu theo thời gian. Nếu không resample về cùng một chuẩn, mô hình có thể học nhầm sự khác biệt về định dạng thay vì đặc trưng âm học của lớp.




Figure 2.2: Phân phối sample rate

2.6.3 Phân tích số kênh âm thanh

UrbanSound8K bao gồm cả dữ liệu mono và stereo. Để tạo sự đồng nhất cho đầu vào mô hình, việc chuyển toàn bộ tín hiệu về mono là cần thiết. Bước này cũng giúp giảm độ phức tạp tính toán, đồng thời đảm bảo mọi mẫu đầu vào có cùng số chiều.




Figure 2.3: Phân phối kênh

2.6.4 Phân tích thời lượng audio

Độ dài các audio clip cũng không đồng đều, với duration trung bình khoảng 3.61 giây. Vì các mô hình CNN và ResNet yêu cầu đầu vào có kích thước cố định, cần một chiến lược chuẩn hóa thời lượng. Trong đề tài này, mọi mẫu được pad hoặc truncate về 4.0 giây, tương ứng với 88200 mẫu khi resample về 22050 Hz.




Figure 2.4: Phân phối thời lượng âm thanh

2.7 Quyết định tiền xử lý rút ra từ EDA

Từ các kết quả EDA, đề tài đưa ra bốn quyết định tiền xử lý chính:

- Chuyển toàn bộ audio về mono.
- Resample toàn bộ dữ liệu về 22050 Hz.
- Pad hoặc truncate về cùng độ dài 4.0 giây.
- Trích xuất log-Mel spectrogram từ tín hiệu đã chuẩn hóa.

Các quyết định này không chỉ giúp tạo ra đầu vào đồng nhất mà còn phù hợp với đặc trưng của các mô hình học sâu được sử dụng trong đề tài.

3 Tổng quan tài liệu

3.1 Tổng quan về phân loại âm thanh

Phân loại âm thanh là một bài toán cơ bản trong lĩnh vực xử lý tín hiệu và học máy. Mục tiêu là gán nhãn cho một đoạn âm thanh dựa trên nội dung hoặc đặc trưng âm học của nó. Các bài toán trong lĩnh vực này có thể bao gồm nhận diện tiếng nói, phân loại nhạc, nhận diện sự kiện âm thanh, nhận diện tiếng động môi trường hoặc phân tích ngữ cảnh âm thanh.

Khác với dữ liệu ảnh, âm thanh tồn tại tự nhiên dưới dạng tín hiệu một chiều theo thời gian. Tuy nhiên, nếu chỉ sử dụng waveform thô, mô hình sẽ khó học trực tiếp các đặc trưng tần số quan trọng. Vì vậy, nhiều nghiên cứu đã lựa chọn biến đổi tín hiệu sang miền thời gian – tần số để làm nổi bật cấu trúc âm học, từ đó áp dụng các mô hình học sâu hiệu quả hơn.

3.2 Các hướng tiếp cận truyền thống

3.2.1 Đặc trưng thủ công

Trước khi học sâu trở nên phổ biến, các phương pháp phân loại âm thanh thường dựa trên đặc trưng thủ công như MFCC, zero-crossing rate, spectral centroid, chroma, spectral roll-off hoặc các thống kê năng lượng theo dải tần. Những đặc trưng này được thiết kế dựa trên hiểu biết của con người về tín hiệu âm thanh.

Ưu điểm của hướng tiếp cận này là tương đối dễ triển khai và có thể hoạt động tốt trên các bộ dữ liệu nhỏ. Tuy nhiên, hạn chế lớn là hiệu năng phụ thuộc mạnh vào chất lượng đặc trưng được chọn và khó mở rộng sang các bài toán phức tạp hơn.

3.2.2 Bộ phân loại truyền thống

Sau khi trích xuất đặc trưng, các bộ phân loại như SVM, k-NN, Random Forest hoặc Logistic Regression thường được sử dụng. Những phương pháp này có chi phí huấn luyện thấp hơn so với mạng sâu, nhưng khó đạt hiệu năng cao khi dữ liệu âm thanh có tính đa dạng lớn hoặc đặc trưng giữa các lớp phức tạp.

3.3 Sự chuyển dịch sang Deep Learning

Sự phát triển của Deep Learning đã làm thay đổi mạnh cách tiếp cận bài toán phân loại âm thanh. Thay vì phụ thuộc hoàn toàn vào đặc trưng thủ công, các mô hình học sâu có thể tự học biểu diễn đặc trưng từ dữ liệu đầu vào. Khi kết hợp với các biểu diễn như spectrogram, các mạng CNN có thể tận dụng cấu trúc cục bộ theo chiều thời gian và tần số, tương tự như cách chúng hoạt động hiệu quả trên ảnh.

Một ưu điểm nổi bật của Deep Learning là khả năng học đặc trưng phân cấp. Ở các lớp đầu, mô hình học các mẫu đơn giản như biên năng lượng hoặc thay đổi cục bộ. Ở các lớp sâu hơn, mô hình có thể tổng hợp các mẫu này thành các đặc trưng ngữ nghĩa hơn, ví dụ như các cấu trúc âm thanh đặc trưng cho từng lớp.

3.4 Biểu diễn tín hiệu âm thanh trong học sâu

3.4.1 Waveform

Waveform là dạng biểu diễn gốc của tín hiệu âm thanh theo miền thời gian. Hướng học trực tiếp từ waveform có ưu điểm là tránh mất thông tin do biến đổi đặc trưng. Tuy nhiên, với dữ liệu có kích thước nhỏ hoặc phạm vi tài nguyên hạn chế, việc huấn luyện từ waveform thường khó hơn, đòi hỏi mô hình lớn hơn và tối ưu phức tạp hơn.




Figure 3.1: Minh họa waveform của âm thanh siren

3.4.2 Spectrogram

Spectrogram biểu diễn sự phân bố năng lượng của tín hiệu theo thời gian và tần số. Đây là một dạng biểu diễn rất phù hợp với CNN bởi nó có thể được coi như một ảnh hai chiều, trong đó một trục là thời gian và trục còn lại là tần số.




Figure 3.2: Minh họa spectrogram của âm thanh siren

3.4.3 Mel spectrogram và log-Mel spectrogram

Mel spectrogram là spectrogram được chiếu sang thang Mel, gần với cách con người cảm nhận tần số hơn so với thang tuyến tính. Sau đó, việc lấy log năng lượng giúp nén dải giá trị biên độ và làm nổi bật các vùng năng lượng thấp. Kết quả là log-Mel spectrogram, một biểu diễn rất phổ biến trong audio classification.

Trong đề tài này, log-Mel spectrogram được lựa chọn làm đầu vào vì nó cân bằng tốt giữa hiệu quả biểu diễn và độ đơn giản triển khai.

3.5 CNN trong bài toán audio classification

CNN là một trong những kiến trúc cơ bản và hiệu quả nhất khi xử lý log-Mel spectrogram. Các bộ lọc tích chập có thể học được các pattern cục bộ trên mặt phẳng thời gian

– tần số, ví dụ như các dải năng lượng, cấu trúc lặp hoặc sự thay đổi mạnh của tín hiệu.

Một ưu điểm lớn của CNN là cấu trúc không quá sâu, dễ huấn luyện và phù hợp với các bộ dữ liệu có kích thước vừa phải. Chính vì vậy, nhiều nghiên cứu sử dụng CNN như một baseline mạnh trong bài toán phân loại âm thanh, và đề tài này cũng đi theo hướng đó.

3.6 Residual Network và ResNet18

3.6.1 Ý tưởng residual learning

ResNet được đề xuất nhằm giải quyết khó khăn khi huấn luyện mạng sâu. Ý tưởng cốt lõi là thay vì để mỗi tầng học trực tiếp một ánh xạ mới, mạng sẽ học một phần dư so với đầu vào thông qua các kết nối tắt. Cách làm này giúp gradient lan truyền tốt hơn và cho phép xây dựng mô hình sâu hơn mà không gặp quá nhiều vấn đề suy giảm hiệu năng.

3.6.2 Áp dụng ResNet cho spectrogram

Khi áp dụng ResNet cho audio spectrogram, cần có một số điều chỉnh để mô hình phù hợp hơn với dữ liệu đầu vào. Thứ nhất, đầu vào của spectrogram thường là một kênh thay vì ba kênh như ảnh RGB. Thứ hai, các chi tiết cục bộ trong spectrogram rất quan trọng, nên phần stem của mạng cần được điều chỉnh để tránh làm mất quá nhiều thông tin ở giai đoạn đầu.

Trong đề tài này, ResNet18 được sử dụng như một mô hình sâu hơn để so sánh với CNN baseline, đồng thời vẫn giữ phạm vi đủ gọn cho một bài tập lớn cá nhân.

3.7 Data augmentation trong audio classification

3.7.1 Vai trò của augmentation

Data augmentation là một kỹ thuật giúp tăng khả năng tổng quát hóa của mô hình bằng cách tạo ra các biến thể hợp lý từ dữ liệu huấn luyện. Với dữ liệu âm thanh, augmentation có thể được thực hiện trong miền waveform hoặc trong miền spectrogram.

Mục tiêu của augmentation là giúp mô hình học được các đặc trưng bền vững hơn, ít phụ thuộc vào những chi tiết ngẫu nhiên của từng mẫu cụ thể.

3.7.2 Augmentation trong miền spectrogram

Các kỹ thuật augmentation trong miền spectrogram thường bao gồm:

- Thêm nhiễu Gaussian nhẹ.
- Dịch theo trục thời gian.
- Frequency masking.
- Time masking.

Ưu điểm của hướng này là dễ triển khai và tương thích tự nhiên với pipeline sử dụng log-Mel spectrogram. Tuy nhiên, nếu augmentation quá mạnh, mô hình có thể học trên dữ liệu bị biến dạng quá mức và làm giảm Accuracy tổng thể.

3.8 Khoảng trống mà đề tài tập trung

Nhiều nghiên cứu tập trung vào việc tối ưu kiến trúc thật sâu hoặc sử dụng pretrained model để đạt hiệu năng cao. Tuy nhiên, trong phạm vi một bài tập lớn cá nhân, câu hỏi thực tế hơn là: với một pipeline rõ ràng, dễ tái lập và tài nguyên vừa phải, mô hình nào là hợp lý nhất?

Đề tài này không theo đuổi mục tiêu phá kỷ lục hiệu năng, mà tập trung vào:

- xây dựng pipeline hoàn chỉnh,
- triển khai được từ đầu đến cuối,
- phân tích rõ dữ liệu và kết quả,
- so sánh công bằng giữa các mô hình trong cùng một điều kiện.

Đây là khoảng trống thực hành mà đề tài hướng đến: đánh giá hiệu quả của CNN baseline, ResNet18 và augmentation trên cùng một bộ dữ liệu, cùng một biểu diễn đặc trưng và cùng một quy trình tiền xử lý.

4 Triển khai thuật toán Deep Learning

4.1 Tổng quan pipeline

Pipeline của đề tài được xây dựng theo hướng rõ ràng và có thể tái lập, bao gồm các bước chính như sau:

1. Đọc file audio từ bộ dữ liệu UrbanSound8K.

2. Chuẩn hóa tín hiệu về mono.
3. Resample tín hiệu về 22050 Hz.
4. Pad hoặc truncate tín hiệu về thời lượng cố định 4.0 giây.
5. Trích xuất Mel spectrogram.
6. Lấy log của Mel spectrogram để tạo log-Mel spectrogram.
7. Chuẩn hóa đặc trưng.
8. Tạo Dataset và DataLoader cho train, validation và test.
9. Huấn luyện mô hình CNN baseline hoặc ResNet18.
10. Đánh giá mô hình bằng Accuracy, Macro-F1 và confusion matrix.

Pipeline này được tổ chức dưới dạng các file Python riêng biệt trong thư mục `src/`, giúp dễ kiểm thử từng phần, thuận lợi khi chạy trên cả Google Colab và môi trường local.

4.2 Tiền xử lý dữ liệu âm thanh

4.2.1 Chuyển về mono

Do dữ liệu gốc bao gồm cả mono và stereo, tín hiệu đầu vào cần được đưa về cùng số kênh. Trong đề tài này, mọi file audio được chuyển về mono bằng cách gộp các kênh thành một kênh duy nhất. Việc này giúp đảm bảo đầu vào có cùng kích thước theo chiều channel và giảm độ phức tạp của pipeline.

4.2.2 Resample về 22050 Hz

Kết quả EDA cho thấy sample rate của UrbanSound8K không đồng nhất, trải dài từ 8000 Hz đến 192000 Hz. Điều này gây khó khăn cho việc học vì cùng một kiểu âm thanh có thể được biểu diễn khác nhau chỉ do khác sample rate. Vì vậy, toàn bộ dữ liệu được resample về 22050 Hz.

Giá trị 22050 Hz được lựa chọn vì đây là một mức phổ biến trong xử lý âm thanh, đủ để giữ lại phần lớn thông tin hữu ích của các âm thanh đô thị trong khi vẫn giúp giảm tải tính toán so với các mức sample rate cao hơn.

4.2.3 Pad hoặc truncate về 4.0 giây

Độ dài các đoạn âm thanh trong UrbanSound8K không hoàn toàn giống nhau. Để đảm bảo mọi mẫu đầu vào có cùng kích thước, đề tài chuẩn hóa độ dài về 4.0 giây. Với sample rate 22050 Hz, số mẫu tương ứng là:

$$22050 \times 4.0 = 88200$$

Nếu file âm thanh ngắn hơn 4.0 giây, tín hiệu sẽ được pad bằng giá trị 0 ở cuối. Nếu dài hơn 4.0 giây, tín hiệu sẽ được truncate về đúng 88200 mẫu.

4.2.4 Trích xuất log-Mel spectrogram

Sau khi tín hiệu đã được chuẩn hóa về mono, sample rate và độ dài, bước tiếp theo là chuyển từ waveform sang biểu diễn thời gian – tần số. Đề tài sử dụng Mel spectrogram với các tham số:

- $n_fft = 1024$
- $hop_length = 512$
- $n_mels = 128$

Sau đó, biên độ Mel spectrogram được đưa về miền log với tham số $top_db = 80$. Kết quả cuối cùng là log-Mel spectrogram một kênh, đóng vai trò là đặc trưng đầu vào cho mô hình học sâu.

4.2.5 Chuẩn hóa đặc trưng

Sau khi tạo log-Mel spectrogram, đặc trưng được chuẩn hóa để làm ổn định quá trình học. Việc chuẩn hóa giúp giảm chênh lệch quá lớn về biên độ giữa các mẫu, nhờ đó mô hình dễ hội tụ hơn trong quá trình huấn luyện.

4.3 Tổ chức dữ liệu train, validation và test

Dataset được chia dựa trên cấu trúc 10 fold sẵn có của UrbanSound8K. Một fold được dùng làm test, một fold được dùng làm validation, các fold còn lại được dùng cho train. Cách làm này có một số ưu điểm:

- Đảm bảo tập test được tách biệt hoàn toàn khỏi quá trình huấn luyện.

- Giúp việc đánh giá cuối cùng phản ánh đúng khả năng tổng quát hóa của mô hình.
- Phù hợp với cấu trúc dữ liệu gốc và dễ cài đặt trong Dataset/DataLoader.

4.4 Xây dựng Dataset và DataLoader

4.4.1 Thiết kế Dataset

Trong đề tài, `dataset.py` trả về mỗi mẫu dưới dạng một dictionary gồm các thành phần như:

- `feature`: log-Mel spectrogram
- `label`: nhãn số của lớp
- `class_name`: tên lớp
- `file_name`: tên file audio
- `fold`: fold tương ứng
- `audio_path`: đường dẫn file audio

Thiết kế này giúp thuận tiện cho việc debug, theo dõi dữ liệu và phân tích lỗi dự đoán.

4.4.2 Thiết kế DataLoader

DataLoader được xây dựng để trả về ba tập: `train_loader`, `val_loader` và `test_loader`. Điều này cho phép quá trình huấn luyện, xác thực và đánh giá cuối cùng được tách biệt rõ ràng. Ở nhánh `augmentation`, chỉ `train_loader` mới sử dụng dữ liệu tăng cường; `validation` và `test` được giữ nguyên.

4.5 Mô hình CNN

4.5.1 Vai trò của CNN

CNN baseline là mô hình cơ sở đầu tiên được triển khai trong đề tài. Vai trò chính của mô hình này là làm mốc tham chiếu cho các thực nghiệm về sau. Vì CNN có cấu trúc đơn giản hơn ResNet, nó giúp xác định liệu một mô hình không quá sâu nhưng phù hợp với đặc trưng spectrogram có thể đạt hiệu năng đến đâu.

4.5.2 Lý do chọn CNN

Có ba lý do chính để chọn CNN:

- CNN phù hợp tự nhiên với dữ liệu dạng ma trận hai chiều như spectrogram.
- Kiến trúc CNN thường dễ huấn luyện và ít nhạy cảm hơn với tối ưu hóa so với mô hình sâu hơn.
- CNN cung cấp một chuẩn đối chiếu hợp lý để đánh giá liệu ResNet18 có thực sự mang lại lợi ích trong phạm vi bài toán này hay không.

4.6 Mô hình ResNet18

4.6.1 Lý do lựa chọn ResNet18

ResNet18 được chọn vì đây là một mô hình đủ sâu để học đặc trưng phức tạp hơn CNN baseline nhưng vẫn nằm trong phạm vi tài nguyên tính toán phù hợp với một project cá nhân. So với các phiên bản ResNet sâu hơn, ResNet18 cũng có ưu điểm là nhẹ hơn và dễ thử nghiệm.

4.6.2 Điều chỉnh đầu vào cho spectrogram

Do log-Mel spectrogram chỉ có một kênh, lớp tích chập đầu tiên của ResNet18 được chỉnh lại để nhận đầu vào một channel thay vì ba channel như ảnh RGB. Đây là thay đổi cần thiết để mô hình có thể xử lý trực tiếp spectrogram mà không cần lập kênh giả tạo.

4.6.3 Điều chỉnh stem của mô hình

Ngoài việc thay đổi số kênh đầu vào, phần stem của mạng cũng được điều chỉnh để phù hợp hơn với đặc trưng âm thanh. Mục đích là tránh làm mất quá nhiều chi tiết cục bộ ở giai đoạn đầu, vì trong spectrogram, các cấu trúc năng lượng nhỏ theo thời gian hoặc tần số có thể mang ý nghĩa phân biệt quan trọng.

4.7 Data augmentation trong miền spectrogram

4.7.1 Mục tiêu của augmentation

Augmentation được đưa vào để khảo sát liệu việc tăng cường dữ liệu có giúp ResNet18 tổng quát hóa tốt hơn hay không. Đặc biệt, augmentation được kỳ vọng cải thiện hiệu năng trên các lớp khó hoặc các lớp dễ bị lép vế trong quá trình học.

4.7.2 Các phép augmentation được áp dụng

Dựa trên file `dataset_aug.py`, nhánh augmentation trong đề tài sử dụng các phép biến đổi sau:

- thêm nhiễu Gaussian nhẹ,
- dịch theo trục thời gian bằng phép roll,
- frequency masking,
- time masking.

Các phép này chỉ được áp dụng trên tập huấn luyện. Validation và test không sử dụng augmentation nhằm đảm bảo kết quả đánh giá phản ánh đúng năng lực tổng quát hóa của mô hình.

4.7.3 Lý do chọn augmentation trong miền spectrogram

So với augmentation ở miền waveform, augmentation trực tiếp trên spectrogram có ưu điểm là dễ triển khai và phù hợp với pipeline đang sử dụng. Hơn nữa, các phép như masking có thể mô phỏng việc mất mát cục bộ thông tin, từ đó buộc mô hình phải học đặc trưng bền vững hơn.

4.8 Chỉ số đánh giá và theo dõi thí nghiệm

4.8.1 Accuracy

Accuracy là tỷ lệ mẫu được dự đoán đúng trên tổng số mẫu của tập kiểm thử. Đây là chỉ số trực quan và thường được dùng làm thước đo đầu tiên khi đánh giá bài toán phân loại.

4.8.2 Macro-F1

Macro-F1 được tính bằng cách lấy trung bình F1-score của từng lớp. Chỉ số này đặc biệt quan trọng trong bài toán mà các lớp có mức độ khó khác nhau, vì nó giúp phản ánh mức độ cân bằng trong hiệu năng dự đoán của mô hình.



4.8.3 Confusion Matrix

Confusion matrix được sử dụng để quan sát các cặp lớp dễ nhầm lẫn. Đây là công cụ quan trọng trong phần phân tích lỗi, giúp lý giải vì sao Accuracy hoặc Macro-F1 của một mô hình có thể chưa cao.

4.8.4 Weights & Biases

Đề tài tích hợp W&B để theo dõi quá trình huấn luyện và đánh giá. Công cụ này hỗ trợ lưu trữ loss, accuracy, macro-F1, checkpoint và lịch sử các thí nghiệm, từ đó giúp việc so sánh giữa các mô hình trở nên rõ ràng và tái lập hơn.

5 Thiết kế thực nghiệm

5.1 Mục tiêu của phần thực nghiệm

Phần thực nghiệm được xây dựng để trả lời các câu hỏi nghiên cứu đã nêu ở phần mở đầu, đồng thời kiểm chứng tính hiệu quả của pipeline đề xuất. Mục tiêu chính của phần này bao gồm:

- đánh giá hiệu năng tổng thể của từng mô hình,
- so sánh công bằng giữa các mô hình trên cùng một bộ dữ liệu và cùng một đặc trưng đầu vào,
- phân tích tác động của augmentation,
- rút ra nhận xét về mức độ phù hợp của từng hướng tiếp cận trong phạm vi project cá nhân.

5.2 Môi trường và phạm vi thực hiện

Toàn bộ thực nghiệm của đề tài được thực hiện trong học kỳ 252 theo đúng yêu cầu môn học. Mã nguồn được tổ chức dưới dạng các file Python trong thư mục `src/`, có thể chạy trên cả Google Colab và môi trường local. Việc tách riêng logic tiền xử lý, Dataset, huấn luyện, đánh giá và mô hình giúp project dễ kiểm thử và dễ mở rộng.

Đề tài cũng sử dụng Weights & Biases để theo dõi thí nghiệm. Công cụ này cho phép lưu lịch sử huấn luyện, so sánh giữa các lần chạy và hỗ trợ trực quan hóa kết quả.

5.3 Chuẩn đầu vào cố định cho các thí nghiệm

Để đảm bảo việc so sánh công bằng giữa các mô hình, các yếu tố sau được giữ cố định trong toàn bộ thực nghiệm:

- bộ dữ liệu sử dụng là UrbanSound8K,
- biểu diễn đầu vào là log-Mel spectrogram,
- sample rate chuẩn hóa là 22050 Hz,
- thời lượng audio cố định là 4.0 giây,
- số mẫu mỗi đoạn là 88200,
- các tham số đặc trưng gồm $n_fft = 1024$, $hop_length = 512$, $n_mels = 128$, $top_db = 80$,
- chỉ số đánh giá gồm Accuracy, Macro-F1 và confusion matrix.

Việc cố định các thành phần trên giúp sự khác biệt về kết quả chủ yếu đến từ kiến trúc mô hình và chiến lược augmentation thay vì từ thay đổi dữ liệu đầu vào.

5.4 Tổ chức các cấu hình thực nghiệm

Trong học kỳ 252, đề tài đã triển khai ba cấu hình chính:

5.4.1 Cấu hình 1: CNN baseline

Đây là mô hình cơ sở đầu tiên được huấn luyện và đánh giá. Mục tiêu là xây dựng một baseline có hiệu năng đủ tốt, từ đó làm chuẩn tham chiếu cho các cấu hình phức tạp hơn.

5.4.2 Cấu hình 2: ResNet18 improved không pretrained

Cấu hình thứ hai sử dụng ResNet18 đã được chỉnh sửa để phù hợp với đầu vào spectrogram một kênh. Việc không dùng pretrained giúp đánh giá trung thực khả năng học của mô hình từ dữ liệu UrbanSound8K trong phạm vi project.

5.4.3 Cấu hình 3: ResNet18 + augmentation không pretrained

Cấu hình thứ ba sử dụng cùng backbone ResNet18 nhưng bổ sung augmentation ở nhánh dữ liệu huấn luyện. Mục tiêu là kiểm tra xem augmentation có thể cải thiện khả năng tổng quát hóa của mô hình hay không.

5.5 Quy trình huấn luyện và đánh giá

5.5.1 Tách train, validation và test

Quy trình huấn luyện sử dụng ba tập dữ liệu tách biệt:

- tập train để tối ưu tham số mô hình,
- tập validation để theo dõi quá trình huấn luyện và chọn checkpoint phù hợp,
- tập test để đánh giá cuối cùng.

Việc tách ba tập như vậy là cần thiết để tránh overfitting trên dữ liệu validation và đảm bảo tính khách quan của kết quả test.

5.5.2 Quy trình huấn luyện

Với mỗi cấu hình, mô hình được huấn luyện trên tập train, theo dõi trên tập validation và lưu checkpoint tốt nhất. Sau khi quá trình huấn luyện hoàn tất, mô hình tốt nhất mới được dùng để đánh giá trên tập test.

Quy trình này có ý nghĩa quan trọng vì nó đảm bảo rằng các kết quả báo cáo không phải là kết quả của một epoch ngẫu nhiên hoặc của việc tinh chỉnh trực tiếp trên tập test.

5.5.3 Quy trình đánh giá

Sau khi chọn được checkpoint tốt nhất từ validation, mô hình được chạy trên toàn bộ tập test. Các chỉ số Accuracy và Macro-F1 được tính toán, đồng thời confusion matrix và classification report được xuất ra để phục vụ phân tích sâu hơn.

5.6 Tiêu chí so sánh

5.6.1 So sánh theo Accuracy

Accuracy được sử dụng để đánh giá mức độ chính xác tổng thể của mô hình. Chỉ số này đặc biệt hữu ích khi muốn xác định mô hình nào có tỷ lệ dự đoán đúng cao nhất trên toàn bộ tập test.

5.6.2 So sánh theo Macro-F1

Macro-F1 được sử dụng để đánh giá mức độ cân bằng giữa các lớp. Trong bài toán urban sound classification, một mô hình có Accuracy cao chưa chắc đã tốt nếu nó chỉ hoạt động tốt trên một số lớp dễ và hoạt động kém trên các lớp khó. Vì vậy, Macro-F1 là chỉ số không thể thiếu.

5.6.3 So sánh theo confusion matrix và classification report

Confusion matrix giúp xác định các cặp lớp mà mô hình thường nhầm lẫn. Classification report giúp quan sát cụ thể precision, recall và F1-score của từng lớp. Hai công cụ này cho phép phân tích định tính sâu hơn so với chỉ nhìn vào Accuracy và Macro-F1.

5.7 Ý nghĩa của việc sử dụng nhiều mô hình

Việc triển khai nhiều mô hình trong cùng một đề tài mang lại hai lợi ích. Thứ nhất, nó giúp so sánh trực tiếp giữa một mô hình cơ sở đơn giản và một mô hình sâu hơn. Thứ hai, nó cho phép đánh giá tác động của augmentation một cách rõ ràng, vì chỉ cần thay đổi một thành phần trong pipeline mà không làm thay đổi phần còn lại.

Nhờ đó, các kết luận rút ra từ thực nghiệm sẽ có tính thuyết phục hơn so với việc chỉ huấn luyện một mô hình duy nhất.

5.8 Tính tái lập của thực nghiệm

Đề tài chú trọng tính tái lập ở ba mức:

- mã nguồn được chia thành các file chức năng rõ ràng,
- pipeline tiền xử lý được cố định và mô tả minh bạch,
- kết quả thí nghiệm được log bằng W&B.

Điều này giúp người đọc có thể hiểu cách kết quả được tạo ra, đồng thời thuận lợi nếu muốn chạy lại hoặc mở rộng project sau này.

6 Đánh giá, so sánh và phân tích thực nghiệm

6.1 Kết quả tổng quan

Ba cấu hình chính được thực hiện trong đề tài gồm CNN baseline, ResNet18 improved không pretrained và ResNet18 + augmentation không pretrained. Kết quả tổng quan trên

tập test được trình bày trong Bảng 6.1.

Table 6.1: So sánh kết quả tổng quan giữa các mô hình

Mô hình	Test Accuracy	Test Macro-F1
CNN baseline	0.7446	0.7525
ResNet18 improved	0.7297	0.7201
ResNet18 + augmentation	0.7297	0.7617

Từ bảng trên có thể thấy CNN baseline hiện là mô hình có Accuracy cao nhất. Trong khi đó, ResNet18 improved chưa vượt được CNN baseline về cả Accuracy lẫn Macro-F1. Khi bổ sung augmentation, Accuracy của ResNet18 không tăng thêm nhưng Macro-F1 tăng rõ rệt, từ đó cho thấy augmentation đã cải thiện tính cân bằng giữa các lớp.

6.2 Phân tích kết quả của CNN

6.2.1 Hiệu năng tổng thể

CNN baseline đạt Test Accuracy bằng 0.7446 và Test Macro-F1 bằng 0.7525. Đây là kết quả tốt nhất về Accuracy trong ba mô hình đã thử nghiệm. Điều này cho thấy với một pipeline đầu vào đã được chuẩn hóa tốt, một kiến trúc CNN tương đối đơn giản vẫn có thể học hiệu quả các pattern thời gian – tần số trên log-Mel spectrogram.

6.2.2 Ý nghĩa của kết quả CNN

Kết quả của CNN baseline mang hai ý nghĩa quan trọng. Thứ nhất, nó chứng minh rằng pipeline tiền xử lý và biểu diễn đặc trưng của đề tài là hợp lý, vì ngay cả mô hình cơ sở cũng đạt được độ chính xác tương đối tốt. Thứ hai, nó cho thấy một mô hình sâu hơn như ResNet18 không mặc nhiên sẽ vượt trội hơn, đặc biệt khi chưa được tối ưu kỹ về kiến trúc và chiến lược huấn luyện.

6.2.3 Phân tích theo từng lớp

CNN baseline cho các giá trị F1-score theo lớp như sau:

Table 6.2: F1-score theo lớp của CNN baseline

Lớp âm thanh	F1-score
air_conditioner	0.3134
car_horn	0.9000
children_playing	0.7822
dog_bark	0.8259
drilling	0.6533
engine_idling	0.7948
gun_shot	0.8889
jackhammer	0.6614
siren	0.8780
street_music	0.8272

Có thể thấy các lớp như **car_horn**, **gun_shot** và **siren** đạt F1-score rất cao. Đây là các lớp có đặc trưng âm học nổi bật, dễ phân biệt hơn trên miền phổ. Ngược lại, **air_conditioner** là lớp yếu nhất, cho thấy đây là một lớp khó và mô hình dễ nhầm lẫn với các âm thanh nền hoặc âm thanh cơ học khác.



Figure 6.1: Kết quả log wandb của CNN

6.3 Phân tích kết quả của ResNet18

6.3.1 Hiệu năng tổng thể

ResNet18 đạt Test Accuracy bằng 0.7297 và Test Macro-F1 bằng 0.7201. So với CNN baseline, mô hình này thấp hơn ở cả hai chỉ số. Điều này cho thấy trong cấu hình hiện tại, độ sâu lớn hơn chưa chuyển thành hiệu năng tốt hơn.

6.3.2 Giải thích khả năng chưa vượt được CNN

Có một số nguyên nhân hợp lý cho việc ResNet18 improved chưa vượt qua CNN baseline.

Thứ nhất, ResNet18 có cấu trúc sâu hơn và do đó nhạy hơn với các siêu tham số huấn luyện. Nếu chiến lược tối ưu chưa đủ phù hợp, mô hình có thể không phát huy hết năng lực biểu diễn.

Thứ hai, UrbanSound8K là một bộ dữ liệu có kích thước vừa phải. Trong nhiều trường hợp, các kiến trúc quá phức tạp có thể không mang lại lợi ích rõ ràng nếu dữ liệu chưa đủ lớn hoặc chưa được augmentation và regularization hợp lý.

Thứ ba, mặc dù ResNet18 đã được điều chỉnh cho đầu vào spectrogram, việc tối ưu phần stem và recipe huấn luyện vẫn còn dư địa cải thiện.

6.3.3 Phân tích theo từng lớp

Kết quả F1-score theo lớp của ResNet18 improved như sau:

Table 6.3: F1-score theo lớp của ResNet18 improved

Lớp âm thanh	F1-score
air_conditioner	0.0893
car_horn	0.8358
children_playing	0.8137
dog_bark	0.7209
drilling	0.6019
engine_idling	0.8657
gun_shot	0.8500
jackhammer	0.6582
siren	0.9277
street_music	0.8372

Một điểm rất đáng chú ý là lớp `air_conditioner` giảm mạnh xuống F1-score 0.0893. Điều này cho thấy ResNet18 đang gặp khó khăn đặc biệt với lớp này, có thể do mô hình thiên về các đặc trưng mạnh hơn và bỏ qua các pattern yếu, mang tính nền.



Figure 6.2: Kết quả resnet từ wandb

6.4 Phân tích kết quả của ResNet18 + augmentation

6.4.1 Hiệu năng tổng thể

ResNet18 + augmentation đạt Test Accuracy bằng 0.7297, bằng với ResNet18 improved, nhưng Test Macro-F1 tăng lên 0.7617. Đây là điểm nổi bật nhất trong toàn bộ

phần thực nghiệm: augmentation không làm tăng Accuracy, nhưng lại cải thiện đáng kể sự cân bằng hiệu năng giữa các lớp.

6.4.2 Ý nghĩa của việc Macro-F1 tăng

Macro-F1 tăng từ 0.7201 lên 0.7617 cho thấy augmentation đã giúp mô hình học tốt hơn trên các lớp khó hoặc các lớp dễ bị lép vế. Điều này đặc biệt quan trọng trong bối cảnh urban sound classification, nơi mà các lớp không đồng đều về mức độ dễ nhận diện.

Nếu chỉ nhìn vào Accuracy, người ta có thể kết luận rằng augmentation không có ích. Tuy nhiên, Macro-F1 cho thấy một bức tranh khác: augmentation giúp mô hình công bằng hơn giữa các lớp, từ đó cải thiện chất lượng thực tế của hệ thống.

6.4.3 Phân tích theo từng lớp

F1-score theo lớp của ResNet18 + augmentation như sau:

Table 6.4: F1-score theo lớp của ResNet18 + augmentation

Lớp âm thanh	F1-score
air_conditioner	0.3723
car_horn	0.9859
children_playing	0.8532
dog_bark	0.8214
drilling	0.5894
engine_idling	0.7136
gun_shot	0.9577
jackhammer	0.6038
siren	0.8627
street_music	0.8571

So với ResNet18, augmentation đã cải thiện rất rõ lớp **air_conditioner**, từ 0.0893 lên 0.3723. Đây là một cải thiện đáng kể và là bằng chứng mạnh cho thấy augmentation giúp mô hình xử lý tốt hơn những lớp khó. Ngoài ra, các lớp như **car_horn**, **children_playing**, **dog_bark**, **gun_shot** và **street_music** cũng có kết quả rất tích cực.

Tuy nhiên, không phải mọi lớp đều tăng. Ví dụ, **engine_idling** giảm từ 0.8657 xuống 0.7136. Điều này gợi ý rằng augmentation hiện tại đang tạo ra một sự đánh đổi: mô hình

trở nên cân bằng hơn nhưng mất đi một phần độ sắc bén ở một số lớp vốn đã mạnh.



Figure 6.3: Kết quả Resnet với bộ dữ liệu tăng cường

6.5 So sánh trực tiếp giữa ba mô hình

6.5.1 So sánh theo Accuracy

Nếu dùng Accuracy làm tiêu chí chính, CNN baseline là mô hình tốt nhất trong đề tài tại thời điểm hiện tại. Điều này là một kết luận quan trọng, vì nó cho thấy mô hình đơn giản hơn có thể phù hợp hơn với bộ dữ liệu và cấu hình thực nghiệm hiện tại.

6.5.2 So sánh theo Macro-F1

Nếu dùng Macro-F1, ResNet18 + augmentation là mô hình tốt nhất với giá trị 0.7617. Điều này cho thấy augmentation mang lại lợi ích thực sự, đặc biệt nếu mục tiêu không chỉ là dự đoán đúng tổng thể mà còn là hoạt động ổn định hơn giữa các lớp.

6.5.3 Góc nhìn cân bằng

Từ hai góc nhìn trên, có thể nói:

- CNN baseline là lựa chọn tốt nhất nếu ưu tiên Accuracy.
- ResNet18 + augmentation là lựa chọn tốt nhất nếu ưu tiên sự cân bằng giữa các lớp.

Đây cũng là minh chứng cho việc không nên chỉ sử dụng duy nhất một chỉ số để kết luận mô hình nào là tốt nhất.

6.6 Phân tích confusion matrix

Confusion matrix là công cụ quan trọng để phân tích chi tiết các lỗi dự đoán. Trong đề tài này, confusion matrix sẽ được chèn dưới dạng hình ảnh được xuất từ quá trình evaluate.




Figure 6.4: Confusion Matrix của CNN




Figure 6.5: Confusion Matrix của ResNet18




Figure 6.6: Confusion Matrix của ResNet18 + augmentation

Dựa trên bản chất của các lớp và kết quả F1-score, có thể kỳ vọng confusion matrix sẽ cho thấy một số cặp nhầm lẫn đáng chú ý, chẳng hạn như:

- `drilling` và `jackhammer`,
- `air_conditioner` và `engine_idling`,
- các trường hợp âm thanh nền yếu bị nhầm sang lớp cơ khí hoặc môi trường liên tục.

Phân tích confusion matrix sẽ giúp lý giải cụ thể hơn vì sao Accuracy và Macro-F1 của từng mô hình lại có xu hướng như đã quan sát.

6.7 Trả lời các câu hỏi nghiên cứu

6.7.1 CNN baseline và ResNet18 khác nhau như thế nào?

Kết quả cho thấy CNN baseline đang vượt ResNet18 improved về Accuracy và Macro-F1. Điều này cho thấy trong điều kiện hiện tại, kiến trúc đơn giản hơn lại phù hợp hơn với bài toán.

6.7.2 Việc điều chỉnh ResNet18 cho spectrogram có giúp hay không?

Việc điều chỉnh ResNet18 là cần thiết để mô hình có thể hoạt động trên log-Mel spectrogram một kênh. Tuy nhiên, chỉ riêng thay đổi kiến trúc là chưa đủ để mô hình vượt qua CNN baseline. Điều này cho thấy hiệu năng của ResNet còn phụ thuộc mạnh vào chiến lược huấn luyện và regularization.

6.7.3 Augmentation có tác động như thế nào?

Augmentation không giúp tăng Accuracy trong cấu hình hiện tại, nhưng giúp tăng Macro-F1 một cách rõ rệt. Điều này chứng tỏ augmentation có ích trong việc cải thiện sự cân bằng giữa các lớp, đặc biệt là với những lớp khó như `air_conditioner`.

6.8 Hạn chế của đề tài

Mặc dù pipeline đã hoàn chỉnh và có kết quả rõ ràng, đề tài vẫn tồn tại một số hạn chế:

- Chưa khảo sát sâu các chiến lược tuning cho ResNet18.
- Chưa thử nhiều phiên bản augmentation khác nhau để tìm mức độ tối ưu.

- Chưa đánh giá trên nhiều cách chia fold khác nhau.
- Chưa mở rộng sang các kỹ thuật như MixUp, OneCycleLR, label smoothing hoặc ensemble.
- Phần related work mới dừng ở mức tổng quan, chưa đi sâu vào phân tích từng nghiên cứu cụ thể.

Tuy nhiên, trong phạm vi một bài tập lớn cá nhân, các kết quả hiện có vẫn đủ để rút ra các kết luận có ý nghĩa.

7 Kết luận và hướng phát triển

7.1 Kết luận chung

Báo cáo này đã trình bày một pipeline hoàn chỉnh cho bài toán phân loại âm thanh đô thị trên bộ dữ liệu UrbanSound8K bằng Deep Learning. Từ bước xác định bài toán, phân tích dữ liệu, thiết kế pipeline tiền xử lý, xây dựng Dataset/DataLoader, triển khai mô hình cho đến đánh giá và thảo luận kết quả, toàn bộ quy trình đã được thực hiện một cách có hệ thống.

Một điểm quan trọng của đề tài là dữ liệu âm thanh gốc có mức độ không đồng nhất cao, cả về sample rate, số kênh và độ dài. Thông qua EDA, đề tài đã đưa ra được các quyết định tiền xử lý hợp lý, bao gồm chuyển mono, resample về 22050 Hz, chuẩn hóa về 4.0 giây và trích xuất log-Mel spectrogram. Các bước này tạo nền tảng ổn định cho toàn bộ phần còn lại của pipeline.

7.2 Những kết quả nổi bật

Đề tài đã thực hiện và đánh giá ba cấu hình mô hình:

- CNN baseline,
- ResNet18 improved không pretrained,
- ResNet18 + augmentation không pretrained.

Kết quả thực nghiệm cho thấy:

- CNN baseline đạt Accuracy cao nhất, cho thấy một kiến trúc đơn giản nhưng phù hợp có thể hoạt động rất hiệu quả trên UrbanSound8K.



- ResNet18 improved chưa vượt được CNN baseline, từ đó cho thấy kiến trúc sâu hơn chưa chắc tự động tốt hơn.
- ResNet18 + augmentation không cải thiện Accuracy nhưng tăng đáng kể Macro-F1, cho thấy augmentation giúp mô hình cân bằng hơn giữa các lớp.

7.3 Ý nghĩa học thuật và thực tiễn

Về mặt học thuật, đề tài giúp làm rõ rằng trong bài toán audio classification, hiệu năng mô hình phụ thuộc không chỉ vào kiến trúc mà còn rất nhiều vào chất lượng tiền xử lý và biểu diễn đặc trưng. Việc so sánh giữa CNN baseline và ResNet18 cho thấy một mô hình sâu hơn chưa chắc vượt trội hơn nếu pipeline huấn luyện chưa được tối ưu phù hợp.

Về mặt thực tiễn, project đã xây dựng được một hệ thống có khả năng tái lập tốt và đủ rõ ràng để mở rộng tiếp. Các thành phần như preprocessing, Dataset, train, evaluate và W&B logging đều đã được tách riêng và có thể tái sử dụng trong các nghiên cứu tiếp theo.

7.4 Hướng phát triển tiếp theo

Nếu tiếp tục phát triển đề tài trong tương lai, có thể xem xét các hướng sau:

- tinh chỉnh thêm chiến lược augmentation để tăng Accuracy mà vẫn giữ được Macro-F1 cao,
- thử nghiệm các kỹ thuật huấn luyện như AdamW, OneCycleLR, label smoothing hoặc MixUp,
- khảo sát thêm các biến thể CNN hoặc ResNet sâu hơn nhưng vẫn không pretrained,
- thực hiện đánh giá trên nhiều cách chia fold khác nhau để kiểm tra tính ổn định,
- mở rộng phần tổng quan tài liệu theo hướng có trích dẫn chi tiết hơn.