

VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY
FACULTY OF COMPUTER SCIENCE AND ENGINEERING



HK251

Báo cáo Bài tập lớn (học phần Học Sâu)

**Phân loại âm thanh đô thị
trên bộ dữ liệu
UrbanSound8K sử dụng
Log-Mel Spectrogram và
CNN, ResNet**

Advisor(s): Thầy Huỳnh Văn Thống

Student(s): Ngô Thái Minh Tiến 2252809

HO CHI MINH CITY, MAY 2026

Contents

1	Mở đầu	1
1.1	Bối cảnh nghiên cứu	1
1.2	Động lực thực hiện đề tài	1
1.3	Mục tiêu nghiên cứu	2
1.4	Cấu trúc báo cáo	2
2	Xác định bài toán và bộ dữ liệu	3
2.1	Phát biểu bài toán	3
2.2	Ý nghĩa của bài toán urban sound classification	3
2.3	Lý do lựa chọn bộ dữ liệu UrbanSound8K	3
2.4	Mô tả tổng quan về bộ dữ liệu	4
2.5	Các lớp âm thanh trong dataset	5
2.5.1	Đặc điểm chung của các lớp	6
2.5.2	Khó khăn trong phân loại giữa các lớp	6
2.6	Kết quả phân tích dữ liệu khám phá	6
2.6.1	Kiểm tra tính đúng đắn giữa metadata và file audio	6
2.6.2	Phân tích sample rate	7
2.6.3	Phân tích số kênh âm thanh	7
2.6.4	Phân tích thời lượng audio	8
2.7	Quyết định tiền xử lý rút ra từ EDA	9
3	Tổng quan bộ dữ liệu	9
3.1	Phân loại âm thanh môi trường	9
3.2	Hướng tiếp cận truyền thống	9
3.3	Sự chuyển dịch sang học sâu	10
3.4	Biểu diễn tín hiệu âm thanh	10
3.4.1	Waveform	10
3.4.2	Spectrogram	10
3.4.3	Mel spectrogram và log-Mel spectrogram	10
3.5	CNN cho phân loại âm thanh	11
3.6	Mạng phần dư ResNet	11
3.7	Data augmentation trong miền spectrogram	11
3.8	Khoảng trống mà đề tài hướng tới	12



4	Phương pháp và triển khai	12
4.1	Tổng quan pipeline	12
4.2	Tiền xử lý dữ liệu âm thanh	13
4.2.1	Chuyển về mono	13
4.2.2	Resample về 22,05 kHz	13
4.2.3	Chuẩn hóa độ dài về 4,0 giây	13
4.2.4	Trích xuất log-Mel spectrogram	13
4.2.5	Chuẩn hóa đặc trưng	13
4.3	Tổ chức dữ liệu và DataLoader	13
4.4	Mô hình CNN baseline	14
4.5	Mô hình ResNet18	14
4.6	Augmentation trong miền spectrogram	15
4.7	Test-time augmentation và ensemble	15
4.7.1	Test-time augmentation (TTA)	15
4.7.2	Ensemble hai mô hình	15
4.8	Chiến lược huấn luyện	16
4.9	Chỉ số đánh giá và công cụ theo dõi	16
5	Thiết kế thực nghiệm	16
5.1	Mục tiêu và câu hỏi nghiên cứu	16
5.2	Môi trường thực hiện	17
5.3	Chuẩn đầu vào cố định	17
5.4	Bốn cấu hình thực nghiệm	17
5.5	Quy trình huấn luyện và đánh giá	18
5.6	Tiêu chí so sánh	18
5.7	Tính tái lập	19
6	Đánh giá, so sánh và phân tích thực nghiệm	19
6.1	Kết quả tổng quan	19
6.2	Phân tích cấu hình CNN baseline	19
6.3	Phân tích cấu hình ResNet18	21
6.4	Phân tích cấu hình ResNet18 + augmentation	22
6.5	Phân tích cấu hình Ensemble	23
6.6	So sánh trực tiếp bốn cấu hình	24
6.7	Phân tích confusion matrix	24



7	Kết luận và hướng phát triển	27
7.1	Kết luận chung	27
7.2	Những kết quả nổi bật	27
7.3	Ý nghĩa học thuật và thực tiễn	28
7.4	Hướng phát triển	28
7.5	Thông tin nộp bài	28



List of Figures

2.1	Tóm tắt kết quả EDA	5
2.2	Phân phối sample rate	7
2.3	Phân phối kênh	8
2.4	Phân phối thời lượng âm thanh	8
3.1	Waveform của một đoạn âm thanh thuộc lớp siren	10
3.2	Mel spectrogram của cùng đoạn âm thanh siren	10
6.1	Kết quả log wandb của CNN	20
6.2	Kết quả resnet từ wandb	21
6.3	Kết quả Resnet với bộ dữ liệu tăng cường	23
6.4	Confusion Matrix của CNN	25
6.5	Confusion Matrix của ResNet18	26
6.6	Confusion Matrix của ResNet18 + augmentation	26



List of Tables

5.1	Siêu tham số huấn luyện của ba mô hình.	18
6.1	So sánh kết quả tổng quan trên tập test.	19
6.2	F1-score theo lớp – CNN baseline.	20
6.3	F1-score theo lớp – ResNet18.	21
6.4	F1-score theo lớp – ResNet18 + augmentation.	22
6.5	F1-score theo lớp – Ensemble.	23
6.6	F1-score theo lớp của bốn cấu hình. Giá trị in đậm là cao nhất theo hàng.	24

1 Mở đầu

1.1 Bối cảnh nghiên cứu

Học sâu trong vài năm gần đây không còn giới hạn ở dữ liệu ảnh mà đã mở rộng mạnh sang xử lý âm thanh. Khác với ảnh – vốn là một ma trận hai chiều tương đối ổn định – tín hiệu âm thanh là một chuỗi biến thiên theo thời gian, độ dài không cố định và dễ bị nhiễu môi trường chi phối. Chính những đặc điểm này khiến việc nhận diện âm thanh tự động trở thành một bài toán vừa khó vừa đáng làm.

Trong không gian đô thị, âm thanh hiện diện dày đặc: tiếng máy điều hòa, còi xe, tiếng trẻ chơi đùa, chó sủa, máy khoan, động cơ chạy không tải, tiếng súng, búa khoan, còi báo động và nhạc đường phố. Mỗi loại đều mang một phần thông tin về môi trường xung quanh. Một hệ thống biết phân loại chúng có thể phục vụ giám sát môi trường, hỗ trợ thành phố thông minh, cảnh báo sự kiện bất thường hoặc làm đầu vào cho các hệ thống phân tích ngữ cảnh ở mức cao hơn.

Bài toán *urban sound classification* vì vậy có giá trị cả về ứng dụng lẫn học thuật. Hướng tiếp cận phổ biến trong học sâu là không làm việc trực tiếp với dạng sóng thô mà chuyển tín hiệu sang miền thời gian – tần số thông qua spectrogram hoặc Mel spectrogram, rồi đưa biểu diễn hai chiều này vào mạng nơ-ron tích chập. Đề tài này đi theo đúng hướng đó.

1.2 Động lực thực hiện đề tài

Đề tài được lựa chọn trước hết vì nó là một bài toán học sâu nằm *ngoài* miền ảnh quen thuộc. Làm việc với âm thanh buộc người thực hiện phải hiểu rõ vai trò của tiền xử lý và biểu diễn đặc trưng – những bước mà ở bài toán ảnh thường được xem nhẹ. Đây là cơ hội tốt để nhìn lại toàn bộ một pipeline học sâu thay vì chỉ tập trung vào kiến trúc mô hình.

Bộ dữ liệu UrbanSound8K phù hợp với phạm vi một bài tập lớn cá nhân: đủ lớn để kết quả có ý nghĩa nhưng vẫn vừa sức huấn luyện trên tài nguyên hạn chế, lại được cộng đồng nghiên cứu sử dụng rộng rãi nên có nhiều mốc tham chiếu. Cuối cùng, đề tài cho phép triển khai trọn vẹn một quy trình – từ phân tích dữ liệu, tiền xử lý, xây dựng Dataset/DataLoader, huấn luyện, đánh giá đến viết báo cáo – nên rất thích hợp để tổng hợp kiến thức của môn học.

1.3 Mục tiêu nghiên cứu

Mục tiêu tổng quát là xây dựng và đánh giá một hệ thống phân loại âm thanh đô thị trên UrbanSound8K, sử dụng biểu diễn log-Mel spectrogram và các mô hình học sâu. Cụ thể, đề tài hướng tới các nội dung sau:

- Phân tích đặc điểm của UrbanSound8K, đặc biệt là các yếu tố không đồng nhất trong dữ liệu gốc, để rút ra quyết định tiền xử lý.
- Thiết kế một pipeline tiền xử lý thống nhất, đưa toàn bộ dữ liệu về cùng một chuẩn đầu vào và trích xuất log-Mel spectrogram.
- Triển khai một mô hình CNN làm mốc cơ sở, một mô hình ResNet18 được điều chỉnh cho đầu vào spectrogram một kênh, và khảo sát tác động của augmentation trong miền spectrogram.
- Kết hợp các mô hình đã huấn luyện theo hướng ensemble nhằm tận dụng tính bù trừ lỗi giữa chúng.
- Đánh giá và phân tích kết quả bằng Accuracy, Macro-F1, classification report và confusion matrix, từ đó so sánh công bằng giữa các cấu hình.

Cần nói rõ ngay từ đầu rằng đề tài không đặt mục tiêu vượt các kết quả tốt nhất đã công bố trên UrbanSound8K. Trong khuôn khổ một bài tập lớn, câu hỏi thực tế hơn là: với cùng một pipeline rõ ràng và tài nguyên vừa phải, các lựa chọn về kiến trúc và augmentation ảnh hưởng đến kết quả ra sao, và ta rút ra được điều gì từ những khác biệt đó.

1.4 Cấu trúc báo cáo

Phần còn lại của báo cáo được tổ chức như sau. Mục ?? mô tả bài toán và bộ dữ liệu, kèm kết quả phân tích dữ liệu khám phá (EDA). Mục 3 điểm lại các hướng tiếp cận cho phân loại âm thanh. Mục 4 trình bày phương pháp: pipeline tiền xử lý, các mô hình và chiến lược huấn luyện. Mục 5 mô tả thiết kế thực nghiệm. Mục ?? trình bày, so sánh và phân tích kết quả của bốn cấu hình. Mục 7 tổng kết và nêu hướng phát triển.

2 Xác định bài toán và bộ dữ liệu

2.1 Phát biểu bài toán

Bài toán được xét trong đề tài là bài toán phân loại âm thanh đa lớp có giám sát. Với mỗi đoạn âm thanh đầu vào có thời lượng ngắn, mô hình cần dự đoán nhãn tương ứng thuộc một trong mười lớp âm thanh đô thị đã được xác định trước.

Gọi x là một đoạn âm thanh đầu vào và y là nhãn lớp tương ứng. Khi đó, mô hình học sâu cần học một hàm ánh xạ:

$$f(x) \rightarrow y, \quad y \in \{1, 2, \dots, 10\}$$

trong đó đầu ra là xác suất hoặc nhãn lớp dự đoán cho mẫu đầu vào.

Bài toán này thuộc nhóm *supervised multi-class classification*, trong đó dữ liệu huấn luyện bao gồm các cặp (x_i, y_i) và mô hình được tối ưu để giảm sai số dự đoán trên tập huấn luyện, đồng thời đạt khả năng tổng quát hóa tốt trên tập kiểm thử.

2.2 Ý nghĩa của bài toán urban sound classification

Phân loại âm thanh đô thị là một bài toán có ý nghĩa thực tế cao. Trong bối cảnh đô thị hiện đại, các hệ thống tự động có thể sử dụng âm thanh như một nguồn tín hiệu quan trọng để hiểu môi trường xung quanh. Ví dụ, một hệ thống giám sát có thể phát hiện âm thanh bất thường như tiếng súng hoặc còi báo động để phát ra cảnh báo; một hệ thống phân tích giao thông có thể tận dụng âm thanh còi xe hoặc động cơ; một hệ thống quan trắc môi trường sống có thể phân tích mức độ tiếng ồn và thành phần âm thanh đặc trưng của khu vực.

Về mặt học thuật, đây cũng là một bài toán tiêu biểu để kiểm chứng khả năng của các mô hình Deep Learning trên dữ liệu âm thanh. Nó đòi hỏi sự kết hợp giữa xử lý tín hiệu số, biểu diễn đặc trưng và học sâu, từ đó giúp người học hình thành tư duy triển khai pipeline một cách hệ thống.

2.3 Lý do lựa chọn bộ dữ liệu UrbanSound8K

UrbanSound8K được lựa chọn vì đây là một trong những bộ dữ liệu chuẩn cho bài toán phân loại âm thanh môi trường, đặc biệt là âm thanh đô thị. Bộ dữ liệu này có ba ưu điểm nổi bật.

Thứ nhất, dữ liệu đã được gán nhãn rõ ràng theo từng lớp âm thanh, giúp phù hợp với bài toán phân loại có giám sát.

Thứ hai, bộ dữ liệu được chia sẵn thành 10 fold, tạo điều kiện thuận lợi cho việc tổ chức thí nghiệm theo train, validation và test mà vẫn đảm bảo tính tách biệt giữa các tập.

Thứ ba, kích thước dữ liệu ở mức vừa phải, đủ để huấn luyện các mô hình CNN và ResNet trong phạm vi tài nguyên tính toán cá nhân, đồng thời không quá nhỏ để khiến kết quả trở nên thiếu ý nghĩa.

2.4 Mô tả tổng quan về bộ dữ liệu

Theo kết quả EDA đã thực hiện, bộ dữ liệu UrbanSound8K trong đề tài có các đặc điểm chính sau:

- Tổng số mẫu: 8732 audio clips.
- Số lớp: 10.
- Số fold: 10.
- Duration trung bình của các audio clip khoảng 3.61 giây.
- Sample rate không đồng nhất, trải dài từ 8000 Hz đến 192000 Hz.
- Dữ liệu bao gồm cả mono và stereo.

```
{'num_samples': 8732,  
'num_classes': 10,  
'classes': ['air_conditioner',  
'car_horn',  
'children_playing',  
'dog_bark',  
'drilling',  
'engine_idling',  
'gun_shot',  
'jackhammer',  
'siren',  
'street_music'],  
'num_folds': 10,  
'folds': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10],  
'all_files_exist': True,  
'sample_rates': {'8000': 12,  
'11024': 7,  
'11025': 39,  
'16000': 45,  
'22050': 44,  
'24000': 82,  
'32000': 4,  
'44100': 5370,  
'48000': 2502,  
'96000': 610,  
'192000': 17},  
'channels': {'1': 739, '2': 7993},  
'duration_mean': 3.6075218292463376,  
'duration_min': 0.05,  
'duration_max': 4.036647314949202}
```

Figure 2.1: Tóm tắt kết quả EDA

Những đặc điểm này cho thấy dữ liệu gốc có mức độ không đồng nhất đáng kể, do đó cần có một chiến lược tiền xử lý nhất quán trước khi đưa vào huấn luyện mô hình.

2.5 Các lớp âm thanh trong dataset

Mười lớp âm thanh được sử dụng trong đề tài bao gồm:

- air_conditioner
- car_horn
- children_playing
- dog_bark

- `drilling`
- `engine_idling`
- `gun_shot`
- `jackhammer`
- `siren`
- `street_music`

2.5.1 Đặc điểm chung của các lớp

Các lớp trong UrbanSound8K có mức độ đặc trưng âm học khác nhau. Một số lớp như `car_horn`, `gun_shot` hoặc `siren` thường có các đặc trưng tương đối nổi bật và dễ phân biệt nhờ cấu trúc năng lượng tập trung hoặc thay đổi mạnh theo thời gian. Ngược lại, các lớp như `air_conditioner`, `engine_idling`, `drilling` hay `jackhammer` có thể khó hơn do mang tính cơ học, lặp lại và đôi khi có phổ năng lượng tương đối gần nhau.

2.5.2 Khó khăn trong phân loại giữa các lớp

Không phải mọi lớp đều có độ khó như nhau. Một số lớp mang tính liên tục và nhiều nền cao, khiến mô hình dễ nhầm lẫn. Ví dụ, `drilling` và `jackhammer` đều là các âm thanh cơ khí có năng lượng mạnh ở một số vùng tần số; `air_conditioner` và `engine_idling` đều mang tính nền, ổn định và ít biến đổi theo thời gian. Điều này khiến việc chỉ đánh giá bằng Accuracy là chưa đủ, mà cần bổ sung thêm Macro-F1 và confusion matrix.

2.6 Kết quả phân tích dữ liệu khám phá

2.6.1 Kiểm tra tính đúng đắn giữa metadata và file audio

Một bước quan trọng trong EDA là kiểm tra xem metadata có ánh xạ đúng sang các file audio hay không. Kết quả cho thấy việc mapping giữa thông tin trong metadata và file audio thực tế là chính xác hoàn toàn. Điều này đảm bảo rằng các bước xây dựng Dataset và DataLoader về sau sẽ dựa trên dữ liệu đúng, tránh lỗi sai nhãn hoặc sai đường dẫn.

2.6.2 Phân tích sample rate

Dữ liệu gốc có sample rate rất không đồng nhất, từ 8000 Hz đến 192000 Hz. Đây là một vấn đề quan trọng bởi sample rate ảnh hưởng trực tiếp đến miền tần số có thể biểu diễn và kích thước tín hiệu theo thời gian. Nếu không resample về cùng một chuẩn, mô hình có thể học nhầm sự khác biệt về định dạng thay vì đặc trưng âm học của lớp.




Figure 2.2: Phân phối sample rate

2.6.3 Phân tích số kênh âm thanh

UrbanSound8K bao gồm cả dữ liệu mono và stereo. Để tạo sự đồng nhất cho đầu vào mô hình, việc chuyển toàn bộ tín hiệu về mono là cần thiết. Bước này cũng giúp giảm độ phức tạp tính toán, đồng thời đảm bảo mọi mẫu đầu vào có cùng số chiều.




Figure 2.3: Phân phối kênh

2.6.4 Phân tích thời lượng audio

Độ dài các audio clip cũng không đồng đều, với duration trung bình khoảng 3.61 giây. Vì các mô hình CNN và ResNet yêu cầu đầu vào có kích thước cố định, cần một chiến lược chuẩn hóa thời lượng. Trong đề tài này, mọi mẫu được pad hoặc truncate về 4.0 giây, tương ứng với 88200 mẫu khi resample về 22050 Hz.




Figure 2.4: Phân phối thời lượng âm thanh

2.7 Quyết định tiền xử lý rút ra từ EDA

Từ các kết quả EDA, đề tài đưa ra bốn quyết định tiền xử lý chính:

- Chuyển toàn bộ audio về mono.
- Resample toàn bộ dữ liệu về 22050 Hz.
- Pad hoặc truncate về cùng độ dài 4.0 giây.
- Trích xuất log-Mel spectrogram từ tín hiệu đã chuẩn hóa.

Các quyết định này không chỉ giúp tạo ra đầu vào đồng nhất mà còn phù hợp với đặc trưng của các mô hình học sâu được sử dụng trong đề tài.

3 Tổng quan bộ dữ liệu

3.1 Phân loại âm thanh môi trường

Phân loại âm thanh môi trường (*environmental sound classification*) là một nhánh của xử lý tín hiệu âm thanh, trong đó mục tiêu là gán nhãn cho một đoạn tiếng động dựa trên nội dung của nó. So với nhận dạng tiếng nói hay phân loại nhạc, âm thanh môi trường khó hơn ở chỗ không có cấu trúc lặp rõ ràng như âm vị hay nhịp điệu, lại thường lẫn nhiều nguồn phát cùng lúc. Bộ dữ liệu UrbanSound8K được Salamon và cộng sự giới thiệu năm 2014 chính là để chuẩn hóa việc nghiên cứu mảng này, kèm theo một phân loại học (taxonomy) cho âm thanh đô thị^[7].

Điểm chung của các hệ thống phân loại âm thanh là tín hiệu hiếm khi được xử lý ở dạng sóng thô. Thay vào đó, người ta biến đổi nó sang miền thời gian – tần số để làm lộ ra cấu trúc âm học, rồi mới đưa vào bộ phân loại.

3.2 Hướng tiếp cận truyền thống

Trước khi học sâu trở nên phổ biến, các hệ thống thường dựa trên đặc trưng thủ công kết hợp với bộ phân loại cổ điển. Các đặc trưng hay dùng gồm MFCC, zero-crossing rate, spectral centroid, chroma hay các thống kê năng lượng theo dải tần – tất cả đều được thiết kế dựa trên hiểu biết của con người về tín hiệu. Sau khi trích xuất, đặc trưng được đưa vào SVM, k -NN, Random Forest hoặc Logistic Regression.

Hướng này dễ triển khai và chạy tốt trên dữ liệu nhỏ, nhưng hiệu năng phụ thuộc nặng vào chất lượng đặc trưng được chọn. Khi dữ liệu đa dạng hơn hoặc ranh giới giữa các lớp tinh tế hơn, việc thiết kế đặc trưng thủ công nhanh chóng chạm trần.

3.3 Sự chuyển dịch sang học sâu

Học sâu thay đổi cục diện bằng cách để mô hình *tự học* biểu diễn đặc trưng từ dữ liệu thay vì dựa vào đặc trưng do con người định nghĩa. Khi đầu vào là spectrogram, mạng tích chập có thể khai thác cấu trúc cục bộ trên mặt phẳng thời gian – tần số y như cách nó hoạt động trên ảnh: các tầng đầu học những mẫu đơn giản như biên năng lượng, các tầng sâu hơn tổng hợp chúng thành đặc trưng mang tính ngữ nghĩa. Piczak^[7] là một trong những công trình sớm cho thấy CNN trên log-Mel spectrogram đạt hiệu năng vượt trội so với đặc trưng thủ công trên chính các bộ dữ liệu âm thanh môi trường.

3.4 Biểu diễn tín hiệu âm thanh

3.4.1 Waveform

Waveform là dạng biểu diễn gốc theo miền thời gian. Học trực tiếp từ waveform tránh được mất mát do biến đổi đặc trưng, nhưng đòi hỏi mô hình lớn và quá trình tối ưu phức tạp – thường không phù hợp với dữ liệu cỡ vừa và tài nguyên hạn chế.

waveform_{siren.png}0.72

Figure 3.1: Waveform của một đoạn âm thanh thuộc lớp **siren**.

3.4.2 Spectrogram

Spectrogram mô tả sự phân bố năng lượng của tín hiệu theo thời gian và tần số. Vì có thể coi như một ảnh hai chiều – một trục thời gian, một trục tần số – nó là biểu diễn rất tự nhiên cho CNN.

spectrogram_{siren.png}0.72

Figure 3.2: Mel spectrogram của cùng đoạn âm thanh **siren**.

3.4.3 Mel spectrogram và log-Mel spectrogram

Mel spectrogram là spectrogram được chiếu sang thang Mel – một thang tần số gần với cảm nhận của tai người hơn thang tuyến tính. Lấy thêm log của năng lượng giúp nén dải biên độ và làm nổi các vùng năng lượng yếu, cho ra log-Mel spectrogram. Đây là biểu diễn được dùng phổ biến nhất trong phân loại âm thanh, và cũng là lựa chọn của đề tài vì nó cân bằng tốt giữa khả năng biểu diễn và độ đơn giản khi triển khai.

3.5 CNN cho phân loại âm thanh

CNN là kiến trúc nền tảng khi xử lý log-Mel spectrogram. Các bộ lọc tích chập học được những mẫu cục bộ như dải năng lượng ngang, cấu trúc lặp hay biến đổi đột ngột của tín hiệu. Ưu điểm của một CNN không quá sâu là dễ huấn luyện và ít nhạy với siêu tham số, nên nó thường được dùng làm *baseline* mạnh – đề tài cũng dùng CNN theo đúng vai trò này. Salamon và Bello^[7] còn cho thấy rằng khi kết hợp CNN với data augmentation, hiệu năng trên âm thanh đô thị được cải thiện rõ rệt, đặc biệt ở các lớp vốn ít mẫu hoặc khó.

3.6 Mạng phần dư ResNet

ResNet^[7] được đề xuất để giải quyết khó khăn khi huấn luyện mạng rất sâu. Ý tưởng cốt lõi là thay vì để mỗi khối học trực tiếp một ánh xạ mới, mạng học một *phần dư* cộng vào đầu vào thông qua kết nối tắt (skip connection). Cách làm này giúp gradient lan truyền thuận lợi và cho phép tăng độ sâu mà không suy giảm hiệu năng.

Khi đưa ResNet sang miền spectrogram, cần hai điều chỉnh. Đầu vào spectrogram chỉ có một kênh thay vì ba kênh RGB, nên tầng tích chập đầu phải được sửa lại. Ngoài ra, các chi tiết cục bộ nhỏ trên spectrogram rất quan trọng, nên phần *stem* của mạng – vốn hạ kích thước rất nhanh ở bản gốc cho ảnh – nên được làm nhẹ hơn để không xóa mất thông tin sớm. Đề tài dùng ResNet18 vì nó đủ sâu để học đặc trưng phức tạp hơn CNN baseline nhưng vẫn nhẹ, phù hợp một project cá nhân.

3.7 Data augmentation trong miền spectrogram

Augmentation tạo thêm các biến thể hợp lý từ dữ liệu huấn luyện để mô hình học được đặc trưng bền vững hơn, ít phụ thuộc vào chi tiết ngẫu nhiên của từng mẫu. Với âm thanh, augmentation có thể thực hiện ở miền waveform hoặc miền spectrogram.

SpecAugment^[7] là kỹ thuật tiêu biểu ở miền spectrogram, gồm việc che một dải tần số (*frequency masking*) hoặc một dải thời gian (*time masking*) ngay trên biểu diễn hai chiều. Đề tài sử dụng các phép này cùng với nhiễu Gaussian nhẹ và dịch thời gian. Ngoài ra, MixUp^[7] – trộn tuyến tính hai mẫu và nhãn của chúng – cũng được áp dụng ở mức batch. Một lưu ý quan trọng từ tài liệu: nếu augmentation quá mạnh, mô hình có thể bị huấn luyện trên dữ liệu biến dạng quá mức và giảm hiệu năng – quan sát này được kiểm chứng trực tiếp trong thực nghiệm của đề tài.

3.8 Khoảng trống mà đề tài hướng tới

Nhiều công trình hiện đại theo đuổi hiệu năng tối đa bằng mô hình rất sâu hoặc mô hình tiền huấn luyện quy mô lớn – chẳng hạn PANNs^[7], được huấn luyện trước trên AudioSet. Tuy nhiên, trong phạm vi một bài tập lớn, câu hỏi đáng quan tâm hơn không phải là “mô hình nào mạnh nhất” mà là: với cùng một pipeline minh bạch và tài nguyên vừa phải, các lựa chọn về kiến trúc, augmentation và cách kết hợp mô hình tác động đến kết quả như thế nào. Đề tài tập trung vào khoảng trống thực hành đó: so sánh công bằng CNN baseline, ResNet18 và ResNet18 kèm augmentation trên cùng một dữ liệu và cùng một quy trình, rồi xét xem việc kết hợp chúng theo hướng ensemble có khai thác được tính bù trừ lỗi hay không.

4 Phương pháp và triển khai

4.1 Tổng quan pipeline

Pipeline của đề tài được tổ chức thành các bước rời nhau, mỗi bước nằm trong một file Python riêng dưới thư mục `src/`, để dễ kiểm thử và chạy được trên cả Google Colab lẫn máy cá nhân. Trình tự xử lý như sau:

1. Đọc file âm thanh từ UrbanSound8K.
2. Chuyển tín hiệu về mono.
3. Resample về 22,05 kHz.
4. Pad hoặc cắt về thời lượng cố định 4,0 giây.
5. Trích xuất Mel spectrogram rồi lấy log để được log-Mel spectrogram.
6. Chuẩn hóa đặc trưng.
7. Tạo `Dataset` và `DataLoader` cho train, validation, test.
8. Huấn luyện mô hình (CNN, ResNet18, hoặc ResNet18 + augmentation).
9. Đánh giá bằng Accuracy, Macro-F1, classification report và confusion matrix; với họ ResNet còn áp dụng test-time augmentation.

Một chi tiết kỹ thuật đáng nói: bước trích xuất log-Mel spectrogram được thực hiện một lần cho toàn bộ dữ liệu và lưu lại thành một tệp đặc trưng (*feature cache*). Nhờ đó, các lần huấn luyện sau không phải đọc và biến đổi lại âm thanh, rút ngắn đáng kể thời gian thí nghiệm.

4.2 Tiền xử lý dữ liệu âm thanh

4.2.1 Chuyển về mono

Do dữ liệu trộn mono và stereo, mọi file được đưa về mono bằng cách lấy trung bình các kênh. Bước này chuẩn hóa số chiều kênh của đầu vào và giảm chi phí tính toán.

4.2.2 Resample về 22,05 kHz

EDA cho thấy tần số lấy mẫu trải dài từ 8 kHz đến 192 kHz. Toàn bộ dữ liệu được resample về 22,05 kHz – một mức phổ biến trong xử lý âm thanh, đủ giữ phần lớn thông tin hữu ích của âm thanh đô thị (chủ yếu nằm ở dải tần thấp và trung) trong khi vẫn nhẹ hơn nhiều so với 44,1 kHz.

4.2.3 Chuẩn hóa độ dài về 4,0 giây

Để mọi mẫu có cùng kích thước, độ dài được cố định ở 4,0 giây. Với tần số 22,05 kHz, điều này tương ứng $22050 \times 4,0 = 88200$ mẫu. Đoạn ngắn hơn được pad bằng giá trị 0 ở cuối; đoạn dài hơn được cắt về đúng 88200 mẫu.

4.2.4 Trích xuất log-Mel spectrogram

Tín hiệu sau chuẩn hóa được chuyển sang Mel spectrogram với các tham số: $n_{\text{fft}} = 1024$, $\text{hop_length} = 512$, $n_{\text{mels}} = 128$. Biên độ sau đó được đưa về thang decibel với $\text{top_db} = 80$. Kết quả là một log-Mel spectrogram một kênh kích thước 128×173 (tần số $\times$ thời gian), đóng vai trò đặc trưng đầu vào cho mọi mô hình.

4.2.5 Chuẩn hóa đặc trưng

Mỗi spectrogram được chuẩn hóa về trung bình 0 và độ lệch chuẩn 1. Bước này thu hẹp chênh lệch biên độ giữa các mẫu, giúp quá trình tối ưu ổn định và hội tụ nhanh hơn.

4.3 Tổ chức dữ liệu và DataLoader

Dữ liệu được chia dựa trên cấu trúc 10 fold sẵn có. Trong toàn bộ thực nghiệm, fold 1 được dùng làm tập test, fold 2 làm tập validation, tám fold còn lại làm tập train. Cách chia này đảm bảo tập test hoàn toàn tách khỏi quá trình huấn luyện và việc lựa chọn mô hình.

Mỗi mẫu do `Dataset` trả về là một dictionary gồm: đặc trưng log-Mel, nhãn số, tên lớp, tên file, fold và đường dẫn. Việc giữ kèm tên file và tên lớp tuy không cần cho huấn

luyện nhưng rất tiện khi gỡ lỗi và phân tích các trường hợp dự đoán sai. `DataLoader` trả về ba bộ nạp riêng cho train, validation và test. Ở nhánh có augmentation, chỉ tập train mới được tăng cường; validation và test luôn giữ nguyên để kết quả đánh giá phản ánh đúng năng lực tổng quát hóa.

4.4 Mô hình CNN baseline

CNN baseline là mô hình cơ sở, đóng vai trò mốc tham chiếu cho các cấu hình phức tạp hơn. Kiến trúc gồm bốn khối tích chập với số kênh tăng dần $16 \rightarrow 32 \rightarrow 64 \rightarrow 128$. Mỗi khối gồm một tầng tích chập 3×3 , batch normalization và ReLU; ba khối đầu kèm max pooling 2×2 , khối cuối dùng adaptive average pooling để thu về một vector đặc trưng 128 chiều. Bộ phân loại gồm một tầng ẩn $128 \rightarrow 64$ với ReLU và dropout 0,3, rồi một tầng $64 \rightarrow 10$.

Lý do chọn CNN làm baseline rất rõ ràng: kiến trúc này phù hợp tự nhiên với dữ liệu hai chiều dạng spectrogram, dễ huấn luyện và ít nhạy với siêu tham số. Nó cho biết một mô hình đơn giản nhưng phù hợp có thể đạt tới đâu, từ đó làm chuẩn để đánh giá liệu ResNet18 có thực sự mang lại lợi ích hay không.

4.5 Mô hình ResNet18

ResNet18 được dùng như mô hình sâu hơn, đủ năng lực học các đặc trưng phức tạp mà CNN baseline khó nắm bắt. Đề tài không dùng trọng số tiền huấn luyện, nhằm đánh giá trung thực khả năng học của kiến trúc trực tiếp từ UrbanSound8K. Hai điều chỉnh được thực hiện so với ResNet18 gốc dành cho ảnh:

- **Đầu vào một kênh.** Tầng tích chập đầu được sửa để nhận trực tiếp spectrogram một kênh, thay vì ba kênh RGB, tránh phải nhân bản kênh một cách giả tạo.
- **Stem nhẹ.** Phần stem được giữ ở dạng tích chập 3×3 stride 1, không hạ kích thước sớm bằng pooling. Trên spectrogram, các cấu trúc năng lượng nhỏ theo thời gian hoặc tần số có thể mang ý nghĩa phân biệt, nên cần được giữ lại ở giai đoạn đầu.

Mô hình gồm bốn tầng (stage), mỗi tầng có hai khối `BasicBlock` với kết nối tắt; dropout dạng không gian được chèn trong khối để hạn chế overfitting. Số kênh nền (*base channels*) được dùng như một tham số dung lượng: cấu hình ResNet18 không augmentation dùng base channels 48, còn cấu hình có augmentation nâng lên 64 để bù lại lượng nhiễu mà augmentation đưa vào.

4.6 Augmentation trong miền spectrogram

Nhánh augmentation áp dụng các phép biến đổi sau, *chỉ trên tập train*:

- thêm nhiễu Gaussian nhẹ;
- dịch theo trục thời gian bằng phép roll;
- frequency masking – che một dải tần số;
- time masking – che một dải thời gian.

Ngoài bốn phép trên ở mức từng mẫu, MixUp được áp dụng ở mức batch: với một xác suất nhất định, hai mẫu trong batch được trộn tuyến tính cùng với nhãn của chúng.

Cường độ augmentation đã được tinh chỉnh trong quá trình làm. Cấu hình ban đầu đặt masking khá rộng (che tới khoảng 17% chiều thời gian, hai dải mỗi loại) và MixUp với xác suất 0,5. Quan sát kết quả cho thấy mức này làm hỏng đặc trưng của nhóm âm thanh cơ khí vốn “đều và lặp” – che mất một dải thời gian dài đồng nghĩa với xóa đi chính tính lặp đặc trưng của chúng. Vì vậy, cấu hình cuối cùng giảm độ rộng masking xuống còn một dải hẹp mỗi loại và hạ xác suất MixUp xuống 0,3. Đây là một minh họa cụ thể cho nhận định ở Mục 3: augmentation quá mạnh có thể phản tác dụng.

4.7 Test-time augmentation và ensemble

4.7.1 Test-time augmentation (TTA)

Khi đánh giá họ mô hình ResNet, đề tài áp dụng test-time augmentation. Với mỗi mẫu test, mô hình dự đoán trên ba phiên bản đầu vào – bản gốc và hai bản dịch nhẹ theo trục thời gian – rồi lấy trung bình logit. TTA không phải huấn luyện lại, chi phí thấp, và giúp dự đoán ổn định hơn trước những dịch chuyển nhỏ về thời gian vốn không làm thay đổi nhãn.

4.7.2 Ensemble hai mô hình

Cấu hình thứ tư của đề tài là ensemble giữa ResNet18 và ResNet18 + augmentation. Hai mô hình này được huấn luyện độc lập với cấu hình khác nhau nên có *hồ sơ lỗi* khác nhau: bản không augmentation mạnh ở nhóm âm thanh cơ khí, bản có augmentation mạnh hơn ở một số lớp “trầm” và ít mẫu. Ensemble được thực hiện đơn giản bằng cách lấy trung bình xác suất softmax (sau TTA) của hai mô hình với trọng số bằng nhau. Mục tiêu là khai thác tính bù trừ đó mà không cần huấn luyện thêm.

4.8 Chiến lược huấn luyện

Tất cả mô hình được huấn luyện trên tập train, theo dõi trên tập validation và chỉ checkpoint tốt nhất (theo Accuracy validation) mới được dùng để đánh giá test. Một số điểm chung trong recipe huấn luyện: hàm mất mát là cross-entropy có label smoothing; tối ưu bằng Adam/AdamW^[?]; learning rate được điều chỉnh tự động (CNN dùng ReduceLROnPlateau, họ ResNet dùng cosine annealing); và có early stopping để dừng khi validation không còn cải thiện. ResNet còn dùng gradient clipping và mixed-precision để huấn luyện ổn định, nhanh hơn. Các siêu tham số cụ thể của từng cấu hình được liệt kê ở Mục 5.

4.9 Chỉ số đánh giá và công cụ theo dõi

Đề tài dùng ba nhóm chỉ số. **Accuracy** – tỷ lệ mẫu dự đoán đúng – cho cái nhìn tổng thể nhưng có thể che giấu sự mất cân bằng giữa các lớp. **Macro-F1** – trung bình F1-score của mười lớp – bổ khuyết cho điều đó: vì mỗi lớp đóng góp như nhau bất kể số mẫu, một mô hình chỉ giỏi vài lớp dễ sẽ bị Macro-F1 “phạt”. **Confusion matrix** và **classification report** cho phép phân tích định tính: nhìn ra chính xác cặp lớp nào hay bị nhầm và lớp nào kéo điểm chung xuống.

Toàn bộ quá trình huấn luyện và đánh giá được ghi log bằng Weights & Biases. Công cụ này lưu lại loss, accuracy, Macro-F1 theo từng epoch, lưu checkpoint và lịch sử các lần chạy, nhờ đó việc so sánh giữa các cấu hình trở nên minh bạch và tái lập được.

5 Thiết kế thực nghiệm

5.1 Mục tiêu và câu hỏi nghiên cứu

Phần thực nghiệm được thiết kế để trả lời ba câu hỏi nghiên cứu, đồng thời kiểm chứng tính hiệu quả của pipeline đã đề xuất:

- CH1.** ResNet18 có vượt được CNN baseline hay không, và nếu có thì độ sâu cùng kết nối phần dư đóng góp ra sao?
- CH2.** Augmentation tác động thế nào tới hiệu năng – không chỉ ở mức tổng thể mà còn ở mức từng lớp?
- CH3.** Ensemble hai mô hình ResNet có khai thác được tính bù trừ lỗi giữa chúng để cho kết quả tốt hơn mọi mô hình đơn lẻ hay không?

5.2 Môi trường thực hiện

Toàn bộ thực nghiệm được tiến hành trong học kỳ 252 theo yêu cầu môn học. Mã nguồn được tổ chức thành các file Python trong thư mục `src/`, chạy được trên cả Google Colab (GPU) và máy cá nhân. Việc tách riêng phần tiền xử lý, `Dataset`, mô hình, huấn luyện và đánh giá giúp project dễ kiểm thử và mở rộng. Mọi lần chạy đều được ghi log bằng Weights & Biases.

5.3 Chuẩn đầu vào cố định

Để khác biệt về kết quả chỉ đến từ mô hình chứ không từ dữ liệu, các yếu tố sau được giữ nguyên trong mọi cấu hình:

- bộ dữ liệu UrbanSound8K, chia fold cố định (test = fold 1, val = fold 2);
- đầu vào là log-Mel spectrogram 128×173 ;
- tần số 22,05 kHz, độ dài 4,0 giây (88200 mẫu);
- tham số đặc trưng $n_{\text{fft}} = 1024$, $\text{hop} = 512$, $n_{\text{mels}} = 128$, $\text{top_db} = 80$;
- bộ chỉ số đánh giá gồm Accuracy, Macro-F1 và confusion matrix.

5.4 Bốn cấu hình thực nghiệm

Đề tài triển khai và đánh giá bốn cấu hình. Ba cấu hình đầu là các mô hình được huấn luyện độc lập; cấu hình thứ tư không huấn luyện thêm mà kết hợp hai mô hình ResNet đã có.

C1 – CNN baseline. Mô hình cơ sở, làm mốc tham chiếu.

C2 – ResNet18. ResNet18 chỉnh cho đầu vào spectrogram một kênh, không pretrained, không augmentation.

C3 – ResNet18 + augmentation. Cùng backbone ResNet18 nhưng bổ sung SpecAugment và MixUp ở nhánh train, dung lượng mô hình lớn hơn.

C4 – Ensemble. Trung bình xác suất của C2 và C3 (đều kèm TTA).

Bảng 5.1 tóm tắt siêu tham số huấn luyện của ba mô hình. Các giá trị này được chọn dựa trên thử nghiệm sơ bộ và đặc điểm của từng cấu hình – ví dụ, C3 dùng dropout và weight decay lớn hơn vì augmentation đã đưa thêm nhiễu, nên mô hình cần dung lượng lớn hơn nhưng cũng cần được điều hòa mạnh hơn.

Table 5.1: Siêu tham số huấn luyện của ba mô hình.

Siêu tham số	C1 – CNN	C2 – ResNet18	C3 – ResNet18+aug
Số epoch tối đa	30	40	50
Optimizer	Adam	AdamW	AdamW
Learning rate	1×10^{-3}	5×10^{-4}	3×10^{-4}
Weight decay	1×10^{-4}	1×10^{-4}	1×10^{-3}
Lập lịch LR	ReduceLROnPlateau	Cosine	Cosine
Label smoothing	0,10	0,05	0,05
Dropout	0,30	0,30	0,50
Base channels	–	48	64
Early stopping	5	8	10
Augmentation	Không	Không	SpecAugment + MixUp

5.5 Quy trình huấn luyện và đánh giá

Mỗi mô hình được huấn luyện trên tập train và theo dõi trên tập validation sau từng epoch. Checkpoint có Accuracy validation cao nhất được lưu lại; chỉ checkpoint này – chứ không phải mô hình ở epoch cuối – mới được dùng để đánh giá test. Quy trình này đảm bảo kết quả báo cáo không phải là sản phẩm của một epoch may mắn, cũng không phải kết quả của việc tinh chỉnh trực tiếp trên tập test.

Khi đánh giá, mô hình được chạy trên toàn bộ tập test (fold 1). Với C2, C3 và C4, test-time augmentation được áp dụng như mô tả ở Mục 4. Đầu ra gồm Accuracy, Macro-F1, classification report theo từng lớp và confusion matrix – tất cả được lưu lại để phục vụ phân tích.

5.6 Tiêu chí so sánh

Việc so sánh dựa trên cả khía cạnh định lượng lẫn định tính. Về định lượng, Accuracy cho biết mô hình nào dự đoán đúng nhiều nhất trên toàn tập test, còn Macro-F1 cho biết mô hình nào cân bằng nhất giữa các lớp. Hai chỉ số này không phải lúc nào cũng đồng thuận, và chính sự khác biệt giữa chúng là một phần thông tin đáng giá. Về định tính, confusion matrix và classification report giúp truy ngược: vì sao một mô hình có Accuracy cao nhưng Macro-F1 thấp, hay augmentation thực sự đã thay đổi điều gì ở mức từng lớp.

5.7 Tính tái lập

Đề tài chú trọng tính tái lập ở ba mức. Mã nguồn được chia thành các file chức năng rõ ràng. Pipeline tiền xử lý được cố định và mô tả minh bạch, kèm cơ chế feature cache để mọi lần chạy dùng đúng cùng một đặc trưng. Toàn bộ kết quả thí nghiệm được log bằng W&B, kèm seed cố định ở mức hợp lý. Nhờ vậy, người đọc có thể hiểu kết quả được tạo ra như thế nào và chạy lại khi cần.

6 Đánh giá, so sánh và phân tích thực nghiệm

6.1 Kết quả tổng quan

Bốn cấu hình được đánh giá trên cùng một tập test (fold 1, 873 mẫu). Bảng 6.1 tổng hợp Accuracy và Macro-F1.

Table 6.1: So sánh kết quả tổng quan trên tập test.

Cấu hình	Test Accuracy	Test Macro-F1
C1 – CNN baseline	0,6999	0,7113
C2 – ResNet18	0,7434	0,7625
C3 – ResNet18 + augmentation	0,7274	0,7398
C4 – Ensemble	0,7572	0,7759

Bảng trên cho thấy ba điểm chính. Thứ nhất, ResNet18 vượt CNN baseline một cách rõ ràng – hơn khoảng 4,3 điểm phần trăm Accuracy và 5,1 điểm Macro-F1. Thứ hai, augmentation *đơn lẻ* lại không cải thiện mà còn kéo cả hai chỉ số của ResNet18 xuống đôi chút; lý do nằm ở mức từng lớp và được phân tích kỹ ở Mục 6.4. Thứ ba, ensemble của C2 và C3 cho kết quả tốt nhất ở cả Accuracy lẫn Macro-F1, và là cấu hình duy nhất vượt mốc 0,75 Accuracy. Như vậy, dù C3 yếu hơn C2 khi đứng một mình, nó vẫn đóng góp tích cực khi được kết hợp – một kết quả thoát nhìn nghịch lý nhưng hoàn toàn hợp lý, sẽ được giải thích ở Mục 6.5.

6.2 Phân tích cấu hình CNN baseline

CNN baseline đạt Accuracy 0,6999 và Macro-F1 0,7113. Đây là một mốc cơ sở hợp lý: với một kiến trúc bốn khối tích chập đơn giản, mô hình văn học được phần lớn cấu trúc

thời gian – tần số trên log-Mel spectrogram. Điều này gián tiếp xác nhận pipeline tiền xử lý của đề tài là đúng hướng – nếu đặc trưng đầu vào kém, ngay cả mô hình cơ sở cũng khó đạt tới mức này.

Table 6.2: F1-score theo lớp – CNN baseline.

Lớp	F1	Lớp	F1
air_conditioner	0,6601	engine_idling	0,3697
car_horn	0,9714	gun_shot	0,7209
children_playing	0,7106	jackhammer	0,6306
dog_bark	0,8360	siren	0,8026
drilling	0,6260	street_music	0,7849

F1-score theo từng lớp của CNN (Bảng 6.2) hé lộ điểm yếu cụ thể. Các lớp có đặc trưng nổi bật như **car_horn** (0,97) và **siren** (0,80) đạt điểm cao. Đáng chú ý nhất là **engine_idling**: F1 chỉ 0,37 nhưng precision tới 0,96 trong khi recall chỉ 0,23. Nói cách khác, CNN gần như “ngại” gán nhãn **engine_idling**; khi nó gán thì thường đúng, nhưng đa số mẫu **engine_idling** thực tế lại bị đẩy sang lớp khác. Đây là dấu hiệu sớm của vấn đề nhóm âm thanh cơ khí mà mọi mô hình về sau đều phải đối mặt.

Có thể thấy các lớp như **car_horn**, **gun_shot** và **siren** đạt F1-score rất cao. Đây là các lớp có đặc trưng âm học nổi bật, dễ phân biệt hơn trên miền phổ. Ngược lại, **air_conditioner** là lớp yếu nhất, cho thấy đây là một lớp khó và mô hình dễ nhầm lẫn với các âm thanh nền hoặc âm thanh cơ học khác.




Figure 6.1: Kết quả log wandb của CNN

6.3 Phân tích cấu hình ResNet18

ResNet18 đạt Accuracy 0,7434 và Macro-F1 0,7625, vượt CNN baseline ở cả hai chỉ số. Kết quả này trả lời trực tiếp câu hỏi **CH1**: trong điều kiện thực nghiệm của đề tài, độ sâu lớn hơn cùng kết nối phần dư có chuyển thành hiệu năng tốt hơn. Việc giữ stem nhẹ để bảo toàn chi tiết cục bộ của spectrogram nhiều khả năng đã góp phần vào kết quả này.

Xét theo lớp (Bảng 6.3), ResNet18 cải thiện mạnh nhóm cơ khí so với CNN: **jackhammer** tăng từ 0,63 lên 0,76, **engine_idling** từ 0,37 lên 0,67. Các lớp dễ như **gun_shot** (0,96) và **street_music** (0,87) cũng rất tốt. Tuy nhiên, mô hình lại có một điểm yếu riêng: **air_conditioner** rất xuống F1 0,35 (recall chỉ 0,31). ResNet18 dường như thiên về các đặc trưng năng lượng mạnh và bỏ sót lớp **air_conditioner** vốn trầm, đều và ít nổi bật.

Table 6.3: F1-score theo lớp – ResNet18.

Lớp	F1	Lớp	F1
air_conditioner	0,3503	engine_idling	0,6705
car_horn	0,9167	gun_shot	0,9577
children_playing	0,7725	jackhammer	0,7632
dog_bark	0,8436	siren	0,8449
drilling	0,6400	street_music	0,8660




Figure 6.2: Kết quả resnet từ wandb

6.4 Phân tích cấu hình ResNet18 + augmentation

ResNet18 + augmentation đạt Accuracy 0,7274 và Macro-F1 0,7398 – cùng thấp hơn ResNet18 không augmentation một chút. Nếu chỉ nhìn hai con số này, ta dễ kết luận rằng augmentation không có ích. Nhưng phân tích theo lớp (Bảng 6.4) cho thấy bức tranh tinh tế hơn nhiều: augmentation không làm mô hình “kém đi” một cách đồng đều, mà *địch chuyển* năng lực giữa các lớp.

Table 6.4: F1-score theo lớp – ResNet18 + augmentation.

Lớp	F1	Lớp	F1
air_conditioner	0,4872	engine_idling	0,6749
car_horn	0,8696	gun_shot	0,8831
children_playing	0,8142	jackhammer	0,4725
dog_bark	0,8585	siren	0,8306
drilling	0,6442	street_music	0,8629

Một mặt, augmentation cải thiện rõ những lớp ResNet18 vốn yếu hoặc trung bình: **air_conditioner** tăng từ 0,35 lên 0,49, **children_playing** từ 0,77 lên 0,81, **dog_bark** từ 0,84 lên 0,86. Việc che ngẫu nhiên một phần spectrogram buộc mô hình không bám vào một vài chi tiết mạnh, nhờ đó dễ mất hơn tới các lớp trầm.

Mặt khác, đúng nhóm âm thanh cơ khí lại bị tổn thương. **jackhammer** rớt mạnh từ 0,76 xuống 0,47, **gun_shot** từ 0,96 xuống 0,88. Nguyên nhân khá trực giác: **jackhammer** được nhận diện chủ yếu nhờ tính *lặp đều* theo thời gian; khi time masking che mất một dải thời gian, ta vô tình xóa luôn chính đặc trưng đó. Vì **jackhammer** là lớp đông mẫu nhất trong tập test (120 mẫu), cú rớt này kéo cả Accuracy lẫn Macro-F1 đi xuống. Đây chính là lý do cường độ augmentation đã phải được giảm bớt (Mục 4); ngay cả ở mức nhẹ, sự đánh đổi vẫn còn.

Như vậy, câu trả lời cho **CH2** là: augmentation không phải một cải tiến “miễn phí”. Nó đánh đổi độ sắc bén ở nhóm cơ khí lấy độ bao phủ tốt hơn ở nhóm âm thanh trầm. Đứng một mình, sự đánh đổi này hơi bất lợi – nhưng nó tạo ra một mô hình có hồ sơ lỗi *khác hẳn* ResNet18, và đó lại là điều kiện lý tưởng cho ensemble.



Figure 6.3: Kết quả Resnet với bộ dữ liệu tăng cường

6.5 Phân tích cấu hình Ensemble

Ensemble lấy trung bình xác suất của ResNet18 và ResNet18 + augmentation, đạt Accuracy 0,7572 và Macro-F1 0,7759 – tốt nhất trong cả bốn cấu hình. Quan trọng hơn con số, cách ensemble đạt được kết quả này mới là điều đáng phân tích.

Hai mô hình thành phần mạnh ở hai vùng khác nhau. ResNet18 sắc ở nhóm cơ khí (jackhammer 0,76, gun_shot 0,96); ResNet18 + augmentation bao phủ tốt hơn nhóm trầm (air_conditioner 0,49, children_playing 0,81). Khi trung bình xác suất, mỗi mô hình “kéo” phần nó tự tin và làm dịu phần nó yếu. Kết quả là ensemble không đơn thuần là trung bình cộng của hai mô hình mà thường tốt hơn cả hai ở từng lớp: F1 của jackhammer hồi về 0,67 (so với 0,47 của C3), air_conditioner giữ ở 0,42 (so với 0,35 của C2), còn siren đạt 0,90 – cao hơn cả hai mô hình thành phần.

Table 6.5: F1-score theo lớp – Ensemble.

Lớp	F1	Lớp	F1
air_conditioner	0,4224	engine_idling	0,6937
car_horn	0,9296	gun_shot	0,9444
children_playing	0,8214	jackhammer	0,6730
dog_bark	0,8421	siren	0,8989
drilling	0,6569	street_music	0,8763

Đây là câu trả lời cho **CH3**: ensemble có khai thác được tính bù trừ lỗi. Việc một mô hình yếu hơn (C3) vẫn nâng được kết quả chung cho thấy giá trị của một thành phần

ensemble không nằm ở chỗ nó mạnh tuyệt đối, mà ở chỗ nó *sai khác đi* so với các thành phần còn lại.

6.6 So sánh trực tiếp bốn cấu hình

Bảng 6.6 đặt F1-score theo lớp của cả bốn cấu hình cạnh nhau, giúp nhìn rõ xu hướng.

Table 6.6: F1-score theo lớp của bốn cấu hình. Giá trị in đậm là cao nhất theo hàng.

Lớp	CNN	ResNet18	ResNet18+aug	Ensemble
air_conditioner	0,6601	0,3503	0,4872	0,4224
car_horn	0,9714	0,9167	0,8696	0,9296
children_playing	0,7106	0,7725	0,8142	0,8214
dog_bark	0,8360	0,8436	0,8585	0,8421
drilling	0,6260	0,6400	0,6442	0,6569
engine_idling	0,3697	0,6705	0,6749	0,6937
gun_shot	0,7209	0,9577	0,8831	0,9444
jackhammer	0,6306	0,7632	0,4725	0,6730
siren	0,8026	0,8449	0,8306	0,8989
street_music	0,7849	0,8660	0,8629	0,8763
Macro-F1	0,7113	0,7625	0,7398	0,7759

Bảng này làm rõ vài điều. Ensemble chiếm vị trí cao nhất ở sáu trên mười lớp và ở Macro-F1 tổng – nó không phải mô hình giỏi nhất ở mọi lớp, nhưng ổn định nhất. `air_conditioner` là một ngoại lệ thú vị: CNN baseline lại đạt F1 cao nhất (0,66) cho lớp này, trong khi mọi mô hình ResNet đều chật vật. Điều đó gợi ý rằng `air_conditioner` không phải lớp “khó tuyệt đối”; ResNet đơn giản là đã học một biểu diễn ưu tiên các lớp năng lượng mạnh và đánh đổi bằng lớp trầm này. Cuối cùng, `jackhammer` cho thấy rõ tác động hai chiều của augmentation: cao nhất ở ResNet18 (0,76), thấp hẳn ở ResNet18+aug (0,47), rồi được ensemble kéo lại mức an toàn (0,67).

6.7 Phân tích confusion matrix

Confusion matrix là công cụ quan trọng để phân tích chi tiết các lỗi dự đoán. Trong đề tài này, confusion matrix sẽ được chèn dưới dạng hình ảnh được xuất từ quá trình

evaluate.




Figure 6.4: Confusion Matrix của CNN




Figure 6.5: Confusion Matrix của ResNet18




Figure 6.6: Confusion Matrix của ResNet18 + augmentation

Dựa trên bản chất của các lớp và kết quả F1-score, có thể kỳ vọng confusion matrix sẽ cho thấy một số cặp nhầm lẫn đáng chú ý, chẳng hạn như:

- **drilling** và **jackhammer**,
- **air_conditioner** và **engine_idling**,
- các trường hợp âm thanh nền yếu bị nhầm sang lớp cơ khí hoặc môi trường liên tục.

Phân tích confusion matrix sẽ giúp lý giải cụ thể hơn vì sao Accuracy và Macro-F1 của từng mô hình lại có xu hướng như đã quan sát.

7 Kết luận và hướng phát triển

7.1 Kết luận chung

Báo cáo đã trình bày một pipeline hoàn chỉnh cho bài toán phân loại âm thanh đô thị trên UrbanSound8K bằng học sâu, đi từ xác định bài toán, phân tích dữ liệu, thiết kế tiền xử lý, xây dựng **Dataset/DataLoader**, huấn luyện mô hình cho tới đánh giá và phân tích kết quả.

Một bài học xuyên suốt là vai trò của bước tiền xử lý. Dữ liệu gốc không đồng nhất rõ rệt về tần số lấy mẫu, số kênh và độ dài; nếu bỏ qua, mô hình có nguy cơ học nhầm định dạng thay vì nội dung âm học. Các quyết định rút ra từ EDA – chuyển mono, resample về 22,05 kHz, chuẩn hóa 4,0 giây và trích xuất log-Mel spectrogram – đã tạo nền tảng ổn định để bốn cấu hình được so sánh một cách công bằng.

7.2 Những kết quả nổi bật

Đề tài đã thực hiện và đánh giá bốn cấu hình: CNN baseline, ResNet18, ResNet18 + augmentation, và ensemble của hai mô hình ResNet. Các phát hiện chính:

- **ResNet18 vượt CNN baseline** ở cả Accuracy (0,7434 so với 0,6999) lẫn Macro-F1 (0,7625 so với 0,7113). Trên bài toán này, độ sâu và kết nối phần dư thực sự có ích.
- **Augmentation là một sự đánh đổi, không phải món quà miễn phí.** Khi dùng đơn lẻ, nó hạ nhẹ hiệu năng tổng thể của ResNet18, nhưng tái phân bố năng lực: cải thiện các lớp trầm như **air_conditioner**, đồng thời làm giảm độ sắc ở nhóm cơ khí, rõ nhất là **jackhammer**.



- **Ensemble cho kết quả tốt nhất** – Accuracy 0,7572, Macro-F1 0,7759 – và là cấu hình duy nhất vượt mốc 0,75. Nó thành công nhờ ghép hai mô hình có hồ sơ lỗi khác nhau, chứ không nhờ ghép hai mô hình cùng mạnh.

7.3 Ý nghĩa học thuật và thực tiễn

Về mặt học thuật, đề tài cho thấy hiệu năng trong phân loại âm thanh phụ thuộc vào nhiều yếu tố hơn là chỉ kiến trúc: chất lượng tiền xử lý, mức độ augmentation và cách kết hợp mô hình đều để lại dấu ấn rõ trên kết quả. Trường hợp augmentation là một ví dụ đáng nhớ – một kỹ thuật thường được mặc định là “có lợi” lại có thể gây hại nếu không xét tới bản chất từng lớp dữ liệu.

Về mặt thực tiễn, project để lại một hệ thống có cấu trúc rõ ràng và tái lập tốt. Các thành phần tiền xử lý, Dataset, huấn luyện, đánh giá và logging W&B đều tách biệt, có thể tái sử dụng hoặc mở rộng cho các nghiên cứu tiếp theo.

7.4 Hướng phát triển

Nếu tiếp tục, đề tài có thể được mở rộng theo các hướng sau:

- **Kiểm định chéo 10-fold** theo đúng giao thức chuẩn của UrbanSound8K, để có con số trung bình kèm độ dao động thay vì kết quả trên một fold duy nhất.
- **Đặc trưng giàu hơn** cho nhóm cơ khí – chẳng hạn ghép thêm các kênh delta và delta-delta – nhằm tách `air_conditioner`, `engine_idling`, `drilling` và `jackhammer`.
- **Mô hình tiền huấn luyện** quy mô lớn như PANNs, được tinh chỉnh trên UrbanSound8K, để nâng trần hiệu năng.
- **Khảo sát augmentation có hệ thống** nhằm tìm cấu hình giữ được lợi ích cho lớp trầm mà không phá đặc trưng lặp của nhóm cơ khí.

7.5 Thông tin nộp bài

Mã nguồn, notebook và toàn bộ nhật ký thí nghiệm được công khai tại:

- Mã nguồn (GitHub):
https://github.com/Zackerville/UrbanSoundClassification_DeepLearning_8K
- Nhật ký thí nghiệm (Weights & Biases):
<https://wandb.ai/tien-ngozack2004-ho-chi-minh-city-university-of-technology/urban-sound-classification>