



Phân loại âm thanh đô thị trên UrbanSound8K

Log-Mel Spectrogram • CNN • ResNet18 • Augmentation

Báo cáo Bài tập lớn — Học phần Học Sâu



GVHD: Thầy Huỳnh Văn Thống



Sinh viên: Ngô Thái Minh Tiến — MSSV 2252809



Khoa: KH & KT Máy tính, ĐH Bách Khoa TP.HCM

HK251 • THÁNG 5, 2026

Nội dung trình bày

1. Bài toán & Bộ dữ liệu
2. EDA & Quyết định tiền xử lý
3. Tổng quan tài liệu
4. Pipeline & Mô hình
 - CNN baseline
 - ResNet18
 - ResNet18 + Augmentation
5. Thiết kế thực nghiệm
6. Kết quả & Phân tích
7. Kết luận

1. Bài toán

Urban Sound Classification

Cho một đoạn âm thanh đô thị ngắn → **gán nhãn** vào 1 trong 10 lớp.

$$f(x) \rightarrow y, \quad y \in \{1, 2, \dots, 10\}$$

Ý nghĩa thực tiễn:

- Giám sát môi trường, thành phố thông minh
- Phát hiện âm thanh bất thường (súng, còi báo động)
- Phân tích giao thông, quan trắc tiếng ồn

Phân loại: Supervised multi-class classification

2. Bộ dữ liệu — UrbanSound8K

Thuộc tính	Giá trị
Tổng số mẫu	8732 audio clips
Số lớp	10
Số fold	10 (sẵn)
Duration trung bình	~3.61 giây
Sample rate	8000 – 192000 Hz (không đồng nhất)
Channels	Mono + Stereo

10 lớp âm thanh: air_conditioner, car_horn, children_playing, dog_bark, drilling, engine_idling, gun_shot, jackhammer, siren, street_music

Lý do chọn UrbanSound8K

-  **Nhấn rõ ràng** — phù hợp supervised classification
-  **Đã chia sẵn 10 fold** — dễ tổ chức train/val/test
-  **Kích thước vừa phải** — đủ cho học sâu nhưng vẫn fit Colab/cá nhân
-  **Tiêu chuẩn học thuật** — nhiều paper benchmark trên dataset này

3. EDA — Đặc điểm dữ liệu gốc

Vấn đề phát hiện được:

- **Sample rate không đồng nhất:** 8 kHz → 192 kHz
 - **Mix mono + stereo:** số kênh khác nhau giữa file
 - **Duration không cố định:** trung bình 3.61s nhưng có biến thiên
- Nếu để nguyên, mô hình sẽ học **format khác biệt** thay vì đặc trưng âm học.

Lớp dễ vs lớp khó

Dễ phân biệt	Khó phân biệt (machinery cluster)
car_horn, gun_shot, siren	air_conditioner, engine_idling
dog_bark	drilling, jackhammer

→ Phổ năng lượng các âm máy móc rất giống nhau

Quyết định tiền xử lý

Bước	Lựa chọn	Lý do
Channels	Mono	Đồng nhất, giảm chiều
Sample rate	22050 Hz	Cân bằng thông tin / compute
Duration	4.0 giây (88200 mẫu)	Pad/truncate cố định
Feature	log-Mel spectrogram	Chuẩn cho audio + tương thích CNN

Tham số log-Mel

- `n_fft = 1024`
- `hop_length = 512`
- `n_mels = 128`
- `top_db = 80`

4. Tổng quan tài liệu

Hướng tiếp cận truyền thống

- **Đặc trưng thủ công:** MFCC, ZCR, spectral centroid...
- **Bộ phân loại:** SVM, k-NN, Random Forest

→ Phụ thuộc mạnh vào đặc trưng được chọn, khó scale

Hướng Deep Learning

- Biểu diễn: **waveform** → **spectrogram** → **Mel** → **log-Mel**
- Kiến trúc:
 - **CNN** — chuẩn cho spectrogram (2D pattern thời gian–tần số)
 - **ResNet** — residual learning, học mạng sâu hiệu quả
 - **Augmentation:** SpecAugment, Mixup

Pipeline tổng quan

🎵 Audio → ⚙️ Preprocess → 📊 Feature → 🧠 Model → ✅ Output

Bước	Nội dung
🎵 Input	WAV file từ UrbanSound8K
⚙️ Preprocess	Mono • Resample 22050 Hz • Pad/Truncate 4.0 s (88200 mẫu)
📊 Feature	MelSpectrogram → AmplitudeToDB → Normalize
🎯 Tensor	log-Mel spectrogram [1 × 128 × 173]
🧠 Model	CNN baseline / ResNet18 / ResNet18 + augmentation
✅ Output	Softmax → 1 trong 10 lớp âm thanh đô thị

Tham số log-Mel: `n_fft=1024` • `hop_length=512` • `n_mels=128` • `top_db=80`

5. Mô hình — CNN baseline

Kiến trúc

4 conv blocks (16 $\rightarrow$ 32 $\rightarrow$ 64 $\rightarrow$ 128 channels), mỗi block:

- Conv 3 $\times$ 3 + BatchNorm + ReLU
- MaxPool 2 $\times$ 2 (3 block đầu) / AdaptiveAvgPool (block 4)

Classifier: Flatten $\rightarrow$ FC(128 $\rightarrow$ 64) $\rightarrow$ Dropout(0.3) $\rightarrow$ FC(64 $\rightarrow$ 10)

Vai trò

- **Baseline cơ sở** — chuẩn so sánh cho các mô hình phức tạp hơn
- Đơn giản, ít tham số $\rightarrow$ dễ huấn luyện trên dataset vừa

Mô hình — ResNet18

Kiến trúc tùy chỉnh cho spectrogram

- **Input 1 channel** (thay vì 3 như RGB)
- **Stem điều chỉnh** — giữ chi tiết cục bộ (Conv 3×3 stride 1, không pool sớm)
- 4 stage × 2 BasicBlock với residual connection
- AdaptiveAvgPool + FC(→10)

Ý nghĩa

- **Sâu hơn CNN baseline** → học pattern phức tạp hơn
- **Residual** → gradient lan truyền tốt khi mạng sâu
- **From scratch** — không dùng pretrained để đánh giá thuần kiến trúc

Mô hình — ResNet18 + Augmentation

SpecAugment trên log-Mel

- **Gaussian noise** nhẹ
- **Time shift** (dịch theo trục thời gian)
- **Frequency masking** (che dải tần số)
- **Time masking** (che dải thời gian)

→ Chỉ áp dụng trên **tập train**, validation/test giữ nguyên.

Mục tiêu

- Tăng tính đa dạng dữ liệu → giảm overfit
- Đặc biệt giúp các **lớp khó** (air_conditioner, drilling...)
- Mô phỏng mất mát thông tin cục bộ → buộc model học đặc trưng bền vững

6. Thiết kế thực nghiệm

Cấu hình chung — giữ cố định

- Dataset: UrbanSound8K
- Input: log-Mel spectrogram [1×128×173]
- 1 fold test (fold 1), 1 fold val (fold 2), 8 fold train

3 cấu hình so sánh

ID	Mô hình	Augmentation
C1	CNN baseline	✗
C2	ResNet18 (1-channel, stem điều chỉnh)	✗
C3	ResNet18 + SpecAugment + Mixup	✓

Chỉ số đánh giá

- **Accuracy** — chính xác tổng thể
- **Macro-F1** — cân bằng giữa các lớp
- **Confusion Matrix** — phân tích lỗi định tính

Quy trình train / eval

Training

- Optimizer: Adam / AdamW
- Loss: CrossEntropy + label smoothing
- Scheduler: ReduceLROnPlateau / CosineAnnealing
- **Early stopping** trên val_acc
- W&B logging: loss, acc, F1 mỗi epoch

Evaluation

- Load best checkpoint (theo val_acc)
- Đánh giá trên test set
- Xuất: metrics JSON, classification report CSV, confusion matrix PNG, predictions CSV

Tính tái lập

- Seed cố định, code modular, log đầy đủ qua W&B

7. Kết quả tổng quan

Mô hình	Test Accuracy	Test Macro-F1
CNN baseline	0.7446	0.7525
ResNet18	0.7297	0.7201
ResNet18 + aug	0.7297	0.7617

Nhận xét chính

- ⚡ **CNN baseline** đạt Accuracy cao nhất → kiến trúc đơn giản phù hợp dataset
- = **ResNet18** chưa vượt CNN → kiến trúc sâu hơn ≠ luôn tốt hơn
- 📈 **ResNet18 + aug**: Accuracy bằng ResNet18 nhưng **Macro-F1 tăng rõ rệt (+4.2 điểm)**
→ Augmentation cải thiện **cân bằng giữa các lớp**

CNN baseline — F1 theo lớp

Lớp	F1	Lớp	F1
car_horn	0.900	drilling	0.653
gun_shot	0.889	jackhammer	0.661
siren	0.878	air_conditioner	0.313
street_music	0.827	engine_idling	0.795
dog_bark	0.826	children_playing	0.782

Phát hiện

- **Class dễ:** car_horn, gun_shot, siren (đặc trưng âm học rõ)
- **Class yếu:** air_conditioner F1 chỉ 0.31 → âm nền liên tục, dễ nhầm

ResNet18 — F1 theo lớp

Lớp	F1	Lớp	F1
siren	0.928	dog_bark	0.721
engine_idling	0.866	jackhammer	0.658
gun_shot	0.850	drilling	0.602
street_music	0.837	air_conditioner	0.089
car_horn	0.836	children_playing	0.814

Phát hiện đáng chú ý

- **air_conditioner SUP ĐỒ** F1 = 0.089 (so với CNN 0.313)
- Mô hình thiên về đặc trưng mạnh → bỏ qua âm nền yếu
- → Lý do Macro-F1 thấp hơn CNN baseline

ResNet18 + Augmentation — F1 theo lớp

Lớp	F1	Thay đổi vs ResNet18
car_horn	0.986	+0.150 
gun_shot	0.958	+0.108 
siren	0.863	-0.065 
street_music	0.857	+0.020 
children_playing	0.853	+0.039 
dog_bark	0.821	+0.100 
engine_idling	0.714	-0.152 
jackhammer	0.604	-0.054 
drilling	0.589	-0.013 
air_conditioner	0.372	+0.283  

→ AC tăng **mạnh nhất** nhờ augmentation

Phân tích confusion matrix

Cặp nhầm lẫn chính (kỳ vọng và thực tế)

- **air_conditioner ↔ engine_idling**
 - Cả hai đều là âm nền liên tục, phổ năng lượng tương tự
- **drilling ↔ jackhammer**
 - Đều là âm cơ khí, có dải tần số mạnh tương tự
- Âm thanh môi trường liên tục **để bị nhầm sang lớp machinery**

Augmentation giải quyết được gì?

- ✓ Tăng tính bền vững → giảm nhầm lẫn ở cặp dễ overfit
- ✗ Vẫn chưa giải quyết hoàn toàn confusion giữa machinery class

So sánh trực tiếp

Theo Accuracy

📌 CNN baseline (0.7446) > ResNet18 = ResNet18+aug (0.7297)

Theo Macro-F1

📌 ResNet18 + aug (**0.7617**) > CNN baseline (0.7525) > ResNet18 (0.7201)

Bài học

- Không nên chỉ dùng 1 chỉ số để kết luận mô hình tốt nhất
- Accuracy ưu tiên → CNN
- Cân bằng giữa các lớp → ResNet18 + aug
- Augmentation cải thiện **chất lượng thực tế** dù không tăng Accuracy

Hạn chế của đề tài

- ⚠ **Chỉ 1 fold split** — chưa áp dụng 10-fold CV chuẩn của UrbanSound8K
- ⚠ Chưa khảo sát sâu **tuning** cho ResNet18
- ⚠ Chưa thử nhiều phiên bản **augmentation** khác nhau
- ⚠ Chưa thử các kỹ thuật: **Mixup, OneCycleLR, ensemble**
- ⚠ Phần literature review **chưa đi sâu** từng paper cụ thể

→ Trong phạm vi BTL cá nhân và compute hạn chế, kết quả vẫn đủ rút ra insight có giá trị.

Kết luận

Đã làm

- ✓ Pipeline hoàn chỉnh: EDA → preprocess → train → evaluate
- ✓ So sánh công bằng 3 mô hình trên cùng setup
- ✓ Phân tích định lượng + định tính (per-class F1 + confusion matrix)
- ✓ W&B logging đầy đủ — tái lập được

Insight chính

- 🔑 **Architecture** lớn hơn $\neq$ luôn tốt hơn trên dataset vừa
- 🔑 **Augmentation** quan trọng cho cân bằng lớp, không nhất thiết tăng Accuracy
- 🔑 **Machinery cluster** (AC, engine_idling, drilling, jackhammer) là bottleneck

Tài liệu tham khảo

1. Salamon, J., Jacoby, C., Bello, J. P. (2014). *A dataset and taxonomy for urban sound research*. ACM MM.
2. Salamon, J., Bello, J. P. (2017). *Deep convolutional neural networks and data augmentation for environmental sound classification*. IEEE SPL.
3. He, K. et al. (2016). *Deep residual learning for image recognition*. CVPR.
4. Park, D. S. et al. (2019). *SpecAugment: a simple data augmentation method for ASR*. Interspeech.
5. Piczak, K. J. (2015). *Environmental sound classification with CNN*. IEEE MLSP.
6. Kong, Q. et al. (2020). *PANNs: large-scale pretrained audio neural networks*. IEEE TASLP.

Cảm ơn!

Q & A

Code: https://github.com/Zackerville/UrbanSoundClassification_DeepLearning_8K

W&B: <https://wandb.ai/tien-ngo/zack2004-ho-chi-minh-city-university-of-technology/urban-sound-classification>

Ngô Thái Minh Tiến — 2252809

games.tien.minh@gmail.com